

데이터 증강을 이용한 KoBERT 기반 에세이 자동 평가 성능 향상

고강희⁰¹ 김도국¹

¹인하대학교 컴퓨터공학부

ghko99@gmail.com, dgkim@inha.ac.kr

Improving Automated Essay Scoring based on KoBERT using Data Augmentation

KangHee GO⁰¹ Doguk Kim¹

¹School of Computer Engineering, Inha University

요 약

에세이 자동 평가(AES)는 자연어 처리에 연구에 있어서 그 중요도 및 사회 전반에의 활용도가 높은 분야 중 하나이다. 본 연구에서는 (한)국어 쓰기 교육 분야에서 에세이 글 평가 작업의 생산성 향상 및 평가의 객관성 확보에 이바지하기 위해 데이터 증강기법(Data Augmentation)을 적용한 KoBERT 기반 에세이 자동 평가 모델을 제안한다. 다양한 실험 결과를 통해 데이터 증강기법을 적용한 모델이 Quadratic Weighted Kappa Score와 Pearson Correlation Coefficient 측면에서 기존의 모델보다 더욱 우수한 성능을 보이는 것을 확인하였다.

1. 서론

에세이 자동평가(Automated Essay Scoring; AES) 기술은 대규모 시험에서 수작업으로 채점하는 데 필요한 시간과 비용을 줄일 수 있으며, 평가의 객관성을 확보할 수 있을 뿐 아니라 일관된 평가 기준을 제공해 준다. 최근 NLP 분야에서는 BERT, GPT와 같은 사전학습 언어 모델의 등장과 미세조정(fine-tuning)으로 다양한 작업에서 높은 성능을 얻어낼 수 있었으며 이는 AES에서도 마찬가지이다[1]. 이러한 상황과 더불어 국내 교육 분야의 시스템에도 많은 변화가 일어나고 있다. 최근 국내 교육 시스템은 지식 전달식 수업에서 지식을 창조하는 방향으로 변화하고 있다[3]. 이에 따라 앞으로 국내 서술·논술형 평가는 점차 확대될 것으로 보이며, 한국에서 AES 기술의 수요는 점점 증가할 것으로 전망된다. 최근 한국 AES 관련 연구를 살펴보면 LSTM[3], GRU[4], BERT[2]를 활용한 다양한 AES 모델들이 제시된 바 있다.

하지만 아무리 높은 성능의 모델을 사용한다고 할지라도, 저품질의 데이터가 모델에 활용된다면, 그 성능은 낮아질 수밖에 없다. 본 논문에서는 기존 국내 연구에서 사용되었던 저품질의 데이터를 BERT 기반 모델의 높은 성능에 상응하는 고품질의 데이터로 개선해 줄 수 있는 데이터 증강 기법(Data Augmentation)[1]을 제안하고 이를 바탕으로 AES 성능을 향상시키고자 한다. 그동안 제시되었던 국내 모델들의 단점은, 모델이 글 자체(Topic, Type)에 대한 특징점들을 학습하지 못한다는 것이었다. 사람이 글을 평가할 때 매기는 점수는 글 내부의 어휘나 문법, 단어 사이의 관계뿐만이 아니라, 글의 전체적인 Topic과 글 내부 요소의 관계에 따라서도 충분히 바뀔 수 있다. 따라서 본 연구에서는 기존 데이터에 글의 Topic 혹은 Type 정보를 삽입해 증강 시킨 다음, BERT 기반 AES 모델에 적용해 성능을 개선해 보고자 한다.

2. 관련 연구

2.1. Data Augmentation for Automated Essay Scoring using Transformer Models

LSTM 모델과 BERT, RoBERTa와 같은 Transformer 기반 모델의 성능을 Accuracy Score를 기준으로 비교했을 때, Transformer 기반 모델들이 AES에서 더욱 우수한 성능을 보임을 확인하였다. 또한 Original Essay에 추가적으로 Summary of Topic을 10문장마다 삽입한 증강 데이터를 활용하면 모든 모델에서 더욱 높은 성능을 보임을 확인하였다.

2.2. 논증 구조 정보를 반영한 심층 신경망 기반 에세이 자동 평가 파이프라인 모델

Argument Mining과 RoBERTa 기반 PLM-BiGRU 모델을 사용하여 논증 구조가 반영된 에세이 표현 벡터를 만들고, 평가 항목별 표현 벡터를 학습하면 최종적으로 QWK가 0.084 증가하여 더욱 우수한 성능을 보이는 것이 확인되었다.

2.3. 순환신경망 장단기 기억(LSTM)을 이용한 자동 채점의 가능성 탐색

기존의 RNN이 가지는 장기 의존성의 문제를 극복하는 LSTM 모델을 이용해 에세이 자동 채점의 가능성을 탐색한 결과 RNN 모델에 비해 우수한 성능을 보여주었다. 또한 해당 모델을 6개의 지표(정확성, 정밀도, 재현율, F1, 카파, 상관관계수)로 평가하였을 때, 양호한(moderate) 수준의 성능인 것으로 확인되었다.

2.4. 한국어 에세이 문항 자동 채점을 위한 딥러닝 알고리즘 탐색

RNN, LSTM, GRU 알고리즘을 적용하여 에세이 답안 채점을 위한 채점 모델을 구축하여 그 성능을 비교하였다. 그 결과 LSTM과 GRU 알고리즘 기반의 채점 모델의 성능이 가장 우수한 것으로 나타났으며, LSTM과 GRU




그림 1. 제안하는 데이터 증강을 활용한 AES 모델 개요

알고리즘 기반의 채점모델의 성능은 비슷하지만, 학습 소요 시간 측면에서 GRU모델이 LSTM보다 더욱 효율적인 것으로 나타났다.

3. 제안 방법

본 논문에서는 데이터 증강의 효과를 검증하기 위해 AI-Hub의 ‘에세이 글 평가 데이터’ [5]의 Baseline 모델을 사용했다. 제공되는 Baseline 모델은 총 두 가지다. 첫 번째 모델은 KoBERT 기반 구조로, Augmented Essay가 아닌 Original Essay를 바로 모델에 적용한 구조이다. Original Essay에 대해 토큰화 작업(Tokenization)을 진행하고, 미리 에세이 데이터에 대해 사전 훈련(Fine-tuned)된 KoBERT를 통해 문장별 임베딩을 진행한다. 임베딩된 결과를 이용하여 GRU 모델이 11가지 소분류별 평가지표(Rubric)에 대한 점수를 예측하도록 학습한다[5]. 두 번째는 LSTM 기반 모델이다. Original Essay에 대해 Word2Vec 임베딩 후 LSTM 모델이 Rubric에 대한 점수를 학습한다. 두 가지 모델 중 KoBERT 기반 모델이 더 우수한 성능을 보이는 것이 확인되었으므로 해당 모델을 기준으로 데이터 증강을 적용하였다.

본 연구에서 제안하는 방식은 Original Essay 내의 일정 구간마다 해당 Essay에 대한 Topic이나 Type 정보를 추가하여 증강한 데이터를 모델이 학습하도록 하는 것이다. ‘에세이 글 평가 데이터’는 각 Essay의 내용뿐만 아니라 Topic, Type 등 Essay 자체에 대한 부수적인 정보도 제공하고 있으므로 이를 그대로 활용하도록 한다[5]. 만약 Topic이 포함된 Essay를 모델이 학습하면 모델은 Essay 내용과 Topic 간의 관계 역시 학습을 할 수 있기 때문에 더욱 높은 성능을 기대해 볼 수 있다[1]. AI-Hub의 ‘에세이 글 평가 데이터’는 Topic뿐만 아니라 Type 정보도 제공하므로 [1]에서와는 다르게 Type을 이용한 데이터 증강도 시도하였다. Essay는 총 2개의 Type(수필형, 논술형)으로 구분되며 세부 타입은 5개의 Type(논술형의 경우 주장, 찬성 반대, 대안 제시, 수필형의 경우 설명글, 글짓기)으로 구분되어 있다. 해당 데이터에 대한 평가지표인 Rubric은 Essay Type에 따라 다르게 구성되어 있으므로, Topic이 아닌 Type 정보를 증강한

데이터를 학습해도 모델은 Essay 글 자체와 Type 사이의 관계를 학습해 더 나은 성능을 기대해 볼 수 있다. 따라서 본 연구에서는 각각 2-Type, 5-Type, 50-Topic의 경우에 대한 데이터 증강이 이루어질 때의 성능을 비교해 보았다. 또한 [1]에 따르면 Topic이 들어갈 위치에 따라 성능이 바뀔 수 있다. [1]에서는 Topic이 들어갈 자리를 문장(Line) 단위로 설정하기로 했으며 실험 결과 10 Line마다 Topic을 삽입했을 때 높은 성능을 보였다. 본 연구에서 사용되는 데이터는 [1]에서 사용하는 데이터와 달리 한 Essay의 총 문장 수가 10문장 이하인 경우가 41%로, 평균 문장 수가 매우 적다. 따라서 거의 모든 데이터가 증강기법의 효과를 얻을 수 있는 5 Line까지만 실험을 진행해 최종적으로 가장 높은 성능을 보이는 Type과 Line을 도출해내기로 했다.

4. 실험

4.1 실험 환경

AI-Hub에서 제공하는 ‘에세이 글 평가 데이터’ 데이터셋은 Essay 기본 정보, 작성자 정보, Score 등으로 라벨링 되어 있다. 총 50,400개의 라벨링 데이터로 이루어져 있으며, 전문가의 의견을 통해 구성된 50가지 Topic으로 이루어져 있다. Essay는 최대 11가지 평가 항목(Rubric)을 통해 평가가 이루어진다. Rubric의 평가 항목 11개는 크게 표현, 구성, 내용별로 3개, 4개, 4개 항목으로 구성(수필형은 3개, 4개, 3개)되어 있으며 항목별로 3명의 평가자가 0점에서 3점까지 점수를 매긴다. AES 모델은 이 11개의 항목에 대한 점수를 예측한다. 이때 모델과 평가자 간의 점수 일치도를 측정하기 위해 Quadratic Weighted Kappa Score와 Pearson Correlation Coefficient를 활용한다. 전체 데이터에 대한 10% 테스트 데이터에 대해 결과를 도출해 성능을 비교했으며 하이퍼파라미터는 Baseline 코드에서 사용하는 기본값을 사용했다. 또한 모든 실험에는 Nvidia RTX 3090Ti GPU 1대가 사용되었다.

표 1. Line 및 Type 변화에 따른 AES 모델의 성능 비교 결과

	Type 2		Type 5		Topic 50	
	Kappa	Pearson	Kappa	Pearson	Kappa	Pearson
Line 1	0.8083	0.8249	0.8019	0.8230	0.8255	0.8357
Line 2	0.8000	0.8175	0.8122	0.8245	0.8209	0.8270
Line 3	0.8032	0.8107	0.8144	0.8240	0.8210	0.8261
Line 4	0.8085	0.8231	0.8046	0.8088	0.8218	0.8307
Line 5	0.8118	0.8174	0.8029	0.8209	0.8162	0.8316
Baseline 1 (KoBERT)	Kappa 0.7947				Pearson 0.8152	
Baseline 2 (LSTM)	Kappa 0.7870				Pearson 0.8062	

4.2 실험 결과

표 1을 통해 알 수 있듯이, 두 가지 Baseline 모델의 성능을 비교한 결과 KoBERT 기반 Baseline 모델이 LSTM 기반 Baseline 모델보다 더욱 높은 성능을 보이는 것이 확인되었다. 따라서 증강 데이터는 모두 KoBERT 기반 모델에 적용해 실험을 진행했다. 증강 데이터를 활용했을 때 Quadratic Weighted Kappa Score 기준 모두 0.8 이상인 것으로 보아 데이터 증강을 적용한 모든 경우에 Baseline 모델보다 성능이 개선된 것을 확인했다. [2]에 따르면 QWK 0.401~0.666은 적당한(moderate) 일치, 0.601~0.800은 상당한(Substantial) 일치, 0.801~1.000은 완벽한(Almost perfect) 일치를 의미한다. 데이터 증강을 적용한 AES의 경우 모두 완벽한 일치를 보였으며 기존 베이스라인(상당한 일치)보다 한 단계 높은 일치도를 보이는 것으로 확인했다. Pearson Correlation Coefficient는 Type2-Line3 와 Type5-Line4를 제외하고 모두 베이스라인 모델보다 성능이 개선된 것을 확인했다. Type 별로 최고의 성능을 보이는 Line은 각각 달랐다. Type 2의 경우 QWK 기준으로는 5개의 Line마다 삽입하는 것이 가장 높은 성능을 보였고, Pearson 상관계수를 기준으로는 1개의 Line마다 삽입하는 것이 가장 높았다. 두 평가 지수의 평균으로 비교해봤을 땐 1개의 Line마다 삽입하는 것이 가장 높았다. Type 5의 경우 QWK 기준 3개의 Line마다 삽입하는 것이 가장 높았고 Pearson 상관계수 기준 2개의 Line마다 삽입하는 것이 가장 높았다. 두 평가 지수의 평균으로 봤을 때는 3개의 Line마다 삽입하는 것이 가장 높았다. Topic 50의 경우 QWK와 Pearson 상관계수 모두 1개의 Line마다 삽입하는 것이 가장 높은 성능을 보였다. 최종적으로 Topic 50 - Line 1의 경우가 가장 높은 성능을 보이는 것으로 확인됐다.

5. 결론

본 논문에서는 데이터 증강을 이용하여 KoBERT 기반 에세이 자동 평가 모델의 성능을 개선하였다. 최종적으로 제안하는 방법은 Original Essay의 매 Line마다 Essay 별 Topic을 삽입해 Augmentation 시킨 후 Fine-tuned KoBERT - GRU 모델에 적용하는 것이다. 다양한 실험을 통해서 제안 방법의 성능 개선 효과를 입증하였으며, 특히, 제안하는 데이터 증강을 적용했을 때 QWK 기준으로 모든 경우에 성능이 향상되었다. 그중에서도 Essay의

Topic 정보를 1개의 Line마다 삽입했을 때 가장 높은 성능을 보였으며 베이스라인보다 QWK는 0.0308, Pearson 상관계수는 0.0295 상승했다. 각 Type 별로 최적의 삽입 Line 위치는 모두 다른 것으로 확인되었고, QWK Score 와 Pearson 상관계수의 평균을 기준으로 Topic 50 - Type 5 - Type 2 순으로 성능이 높은 것을 확인했다. 즉, 모델이 좀 더 세분된 정보를 학습했을 때 높은 성능을 보인다. 이러한 결론을 이용해 향후 연구에서는 Essay에 Topic과 Type이 잘 엮인 정보를 삽입해 모델이 더욱 세분된 정보를 학습할 수 있도록 개선하고자 한다.

감사의 글

이 논문은 2023년도 인하대학교의 지원 및 2023년도 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원(No.RS-2022-00155915, 인공지능융합혁신인재양성(인하대학교))을 받아 수행된 연구임

참고 문헌

- [1] GUPTA, Kshitij. "Data Augmentation for Automated Essay Scoring using Transformer Models." In: 2023 International Conference on Artificial Intelligence and Smart Communication (AISC). IEEE, pp. 853-857, 2023
- [2] 이예진, 장영진, 김태일, 최성원, 김학수, "논증 구조 정보를 반영한 심층 신경망 기반 에세이 자동 평가 파이프라인 모델", 제34회 한글 및 한국어 정보처리 학술대회 논문집, pp.354-359, 2022.10.19
- [3] 박강운, 이용상, 신동광, "순환신경망 장단기 기억(LSTM)을 이용한 자동 채점의 가능성 탐색, vol.24, no.4, 통권 24호 pp. 223-238 (16 pages), 2021
- [4] 박강운, 이용상, "한국어 에세이 문항 자동 채점을 위한 딥러닝 알고리즘 탐색" vol.35, no.3, pp. 465-488 (24 pages), 2022
- [5] 데이터 분야 - AI 데이터찾기 - AI-Hub, 에세이 글 평가 데이터, 갱신년월 : 2022-10, 구축년도 : 2021 <https://aihub.or.kr/aihubdata/data/view.do?currMenu=115&topMenu=100&aihubDataSe=realm&dataSetSn=545>