

공학석사학위 논문

생성형 대규모 언어모델 기반 한국어 자동 에세이
채점 성능 개선 연구

Enhancing Korean Automated Essay Scoring with
Generative Large Language Models

2026년 8월

인하대학교 대학원

전기컴퓨터공학과(인공지능전공)

고 강 희

공학석사학위 논문

생성형 대규모 언어모델 기반 한국어 자동 에세이
채점 성능 개선 연구

Enhancing Korean Automated Essay Scoring with
Generative Large Language Models

2026년 8월

지도교수 김 도 국

이 논문을 석사학위 논문으로 제출함

이 논문을 고강희의 석사학위논문으로 인정함.

2026년 6월

주심 김 병 형 (인)

부심 김 도 국 (인)

위원 이 현 규 (인)

목 차

요 약	i
Abstract	ii
서 론	1
관련 연구	5
I. 자동 에세이 채점의 발전	5
II. 생성형 LLM 기반 자동 에세이 채점과 손실 함수 설계	6
III. 자기 일관성과 기대값 디코딩 추론	7
제안 방법	8
I. 모델 아키텍처 및 생성 형식	10
II. 가중 숫자 토큰 손실	12
III. 피드백 의미 정렬 손실	15
IV. 추론 및 디코딩 전략	19
실 험	21
I. 데이터셋 및 실험 환경	21
II. 손실 함수 조합 별 성능 평가 및 비교분석	29
III. 추론 전략 별 성능 평가 및 비교분석	40
IV. 통계적 유의성 분석	47
결 론	50
참고문헌	53
감사의 글	57

그림 1: 제안하는 생성형 LLM 기반 자동 에세이 채점 시스템.....	9
그림 2: 루브릭별 레이블 분포.....	23
그림 3: 루브릭별 채점자 간 일치도 (Inter-Rater QWK)	26
그림 4: 루브릭별 QWK 성능 비교.....	33
그림 5: CE 대비 루브릭별 QWK 개선율(%).....	34
그림 6: 점수 구간 별 오차.....	36
그림 7: 정답 분포와 모델의 예측 점수 분포 비교.....	37
그림 8: 어휘적절성 루브릭에 대한 모델별 혼동 행렬	39
그림 9: Self-Consistency 샘플 수(m)에 따른 QWK 변화	44
그림 10: ED 와 SC 의 루브릭별 QWK 개선폭	46
그림 11: 핵심 비교쌍별 · 루브릭별 $\angle$ QWK 와 통계적 유의성	49
표 1: 루브릭별 상세 평가 기준	22
표 2: 학습 및 추론 하이퍼파라미터	24
표 3: 손실함수 조합별 비교 실험 모델	28
표 4: 손실 함수 구성에 따른 루브릭별 채점 성능(QWK)	31
표 5: 추론 전략에 따른 루브릭별 채점 성능(QWK)	41

요 약

대규모 생성형 언어 모델(LLM) 기반 자동 에세이 채점은 점수와 피드백을 단일 경로에서 함께 생성할 수 있다는 장점이 있지만, 점수 간 서열 관계를 충분히 학습하지 못하고, 점수 분포의 불균형 및 추론 과정의 확률적 변동성으로 인해 채점 정확도와 재현성이 저하될 수 있다. 본 연구는 두 가지 보조 손실 함수와 추론 전략을 분석해 채점 예측의 정확도와 일관성을 높이는 통합 프레임워크를 제안한다. 핵심은 학습 단계에서 점수의 서열 거리와 데이터 불균형을 반영한 손실 함수로 희소 점수대의 예측 오차를 완화하고, 의미론적 정렬 손실을 통해 텍스트 표면에 의존하는 학습 편향을 억제하는 데 있다. 또한 추론 단계에 기대값 기반 디코딩(Expected Value Decoding) 혹은 자기 일관성(Self-Consistency) 전략을 적용해 단일 추론의 확률적 노이즈를 통계적으로 상쇄하고 최종 점수의 안정성을 높인다. AI Hub 데이터셋 실험 결과, 제안 방법(SAL+WNTL 학습과 자기 일관성 평균 집계)의 결합은 기존 베이스라인 대비 평균 이중 가중 카파(Quadratic Weighted Kappa, QWK)를 10.9% 향상시켰으며, 이 개선은 8개 모든 평가 루브릭에서 통계적으로 유의하였다(paired bootstrap, $p < 0.001$). 이는 단일 생성형 모델만으로 베이스라인 수준의 채점 정확도와 유용한 교육적 피드백을 동시에 달성할 수 있음을 보인다.

Abstract

Automatic essay scoring (AES) using large language models (LLMs) can jointly generate scores and feedback in a single pass, but may struggle to learn ordinal score relationships, with accuracy and reproducibility further degraded by class imbalance and stochastic inference variability. This study proposes an integrated framework combining two auxiliary loss functions and inference strategies to improve scoring accuracy and consistency. During training, an ordinal-distance- and imbalance-aware loss mitigates prediction errors on sparse score bands, while a semantic alignment loss suppresses surface-level learning biases. During inference, Expected Value Decoding or Self-Consistency strategies statistically offset single-pass noise to stabilize final scores. On the AI Hub dataset, the proposed method (SAL+WNTL training with self-consistency mean aggregation) improves mean QWK by 10.9% over the baseline, a gain significant across all eight rubrics (paired bootstrap, $p < 0.001$). This shows that a single generative model can match baseline scoring accuracy while also delivering useful pedagogical feedback.

서 론

글쓰기 평가는 학습자의 사고력, 논리 구성 능력, 언어 표현 능력을 종합적으로 측정하는 대표적인 수행 평가 방식으로, 한국의 교육 환경에서 그 비중이 꾸준히 확대되고 있다[1]. 그러나 인간 채점자에 의존하는 전통적 평가 방식은 높은 시간 및 비용 부담과 더불어 채점 일관성 확보의 어려움을 수반한다. 이러한 한계를 극복하기 위한 대안으로 자동 에세이 채점(Automated Essay Scoring, AES)이 지속적으로 주목받아 왔으며, BERT, RoBERTa 등 사전학습 기반 판별 모델의 도입으로 이차 가중 카파(Quadratic Weighted Kappa, QWK) 기준 점수 예측 성능이 크게 향상되었다[6]. 그러나 판별 모델은 구조적으로 점수 산출에만 특화되어 있어, 채점 근거 제시 및 학습자를 위한 구체적인 피드백 생성에는 한계가 있다[7].

최근 GPT, LLaMA 계열의 대규모 생성형 언어 모델(Large Language Model, LLM)의 발전은 이러한 한계를 극복할 새로운 가능성을 제시한다[8, 9]. 생성형 LLM은 루브릭 기반 평가 기준에 따라 점수, 근거, 개선 방향을 단일한 자동회귀 생성 과정에 산출할 수 있어, 설명 가능성과 교육적 활용 가능성을 크게 확장한다. 그러나 이를 실용적인 AES 시스템으로 구현하기 위해서는 다음과 같은 기술적 과제가 선결되어야 한다. 첫째, LLM의 표준 교차 엔트로피(Cross-Entropy, CE) 손실은 점수 토큰을 서로 독립적인 범주로 취급하므로, 점수 간 서열 관계와 거리 정보가 모델 학습에 충분히 반영되지 못한다[12]. 이로 인해 생성형 모델은

AES 평가 지표로 널리 사용되는 QWK와 학습 목표 사이에 불일치가 발생한다. 둘째, 실제 채점 데이터는 중간 점수대에 표본이 집중되는 불균형 분포를 띠어, 희소 점수 구간에서의 예측 성능이 저하되기 쉽다. 셋째, 점수 토큰과 피드백 토큰을 동일한 방식으로 학습할 경우, 두 출력이 서로 다른 역할과 학습 목표를 가짐에도 동일한 토큰 수준 감독이 적용되어 학습 편향이 발생할 수 있다[14]. 특히 상대적으로 긴 피드백 시퀀스는 더 많은 손실을 유발하므로, 전체 최적화 과정에서 점수 예측 신호가 상대적으로 약화될 우려가 있다. 넷째, 생성형 모델의 확률적 특성으로 인해 동일한 입력에 대해서도 매 추론마다 상이한 점수가 산출되어 평가의 신뢰성이 저하될 수 있다[16].

여기서 제시한 네 가지 과제는 특정 언어에 국한되지 않는, 생성형 LLM 기반 AES가 공통적으로 직면하는 일반적 문제다. 그럼에도 본 연구가 한국어 데이터를 실험 대상으로 삼은 이유는 두 가지다. 첫째, 점수와 피드백을 단일 모델로 동시에 생성·검증하려면 루브릭별 점수와 전문가 피드백이 함께 라벨링된 대규모 데이터가 필요하나, 이러한 자원은 언어를 막론하고 매우 제한적이다. 점수·피드백 동시 학습을 목적으로 영어권에서 구축된 LEAF++ [10]는 피드백과 특성 점수를 함께 제공하지만, 피드백이 전문 채점자가 아닌 온라인 작문 포럼에서 수집된 자유형 텍스트이고 특성 점수도 별도로 부가되어 LLM 기반 절차로 검증된 것이며 규모 또한 소규모에 그친다. 점수 위주의 DREsS나 ASAP [11] 등도 총점·특성 점수만 제공할 뿐 전문가 피드백을 포함하지 않는다. 반면 본

연구가 사용하는 AI Hub 서술형 글쓰기 평가 데이터셋[19, 20]은 40,006편의 실제 에세이에 대해 전문 채점자의 루브릭별 점수(특성 점수)와 피드백을 모두 제공하여, 점수·피드백 동시 생성 모델을 대규모로 학습·검증할 수 있는 사실상 유일한 자원이다. 둘째, 한국 교육 현장에서 서술형·논술형 평가의 비중이 확대되는 상황[1]에서 한국어 자동 채점의 실용적 수요가 크다. 따라서 본 연구는 언어에 의존하지 않는 학습·추론 기법을 제안하되, 점수·피드백 동시 라벨이 가장 풍부하게 확보된 한국어 데이터에서 이를 검증한다.

앞서 제시한 생성형 LLM 기반 AES의 기술적 과제를 해결하기 위해, 본 연구는 학습 단계와 추론 단계를 함께 고려하는 통합 프레임워크를 제안한다. 학습 과정에서 점수 구간에는 점수 간 서열 관계를 반영하고 데이터의 불균형 분포를 보정하는 가중 숫자 토큰 손실(Weighted Number Token Loss, WNTL)을 적용한다. 피드백 구간에는 점수 토큰과 피드백 토큰 간 학습 편향을 완화하는 의미 정렬 손실(Semantic Alignment Loss, SAL)을 도입한다. 아울러 추론 단계에서는 기대값 기반 디코딩(Expected Value Decoding, ED)[17] 혹은 자기 일관성(Self-Consistency, SC)[15] 전략을 적용하여 채점 결과의 재현성 및 정확성을 제고한다. 이를 통해 생성형 LLM이 정확한 점수와 설명 가능한 채점 근거를 동시에 확보할 수 있는 실용적 자동 에세이 채점 시스템을 구현하고자 한다. 본 논문의 주요 기여점은 다음과 같이 요약한다.

I. 순서형 점수 예측을 위한 학습 방법 적용 및 성능 개선

- ❖ 본 논문에서는 생성형 LLM 기반 자동 에세이 채점에서 점수의 서열성과 데이터 불균형을 반영할 수 있도록 Weighted Number Token Loss(WNTL)를 적용하여 점수 예측 성능을 향상시켰다.

II. 학습 편향 완화를 통한 채점 정확도 추가 개선

- ❖ 점수 토큰과 피드백 토큰을 학습할 때 발생하는 손실 지배 문제를 완화하기 위해 Semantic Alignment Loss(SAL)를 도입하여 채점 정확도를 추가 개선하였다.

III. 추론 전략 고도화를 통한 채점 신뢰성 향상

- ❖ 기대값 기반 디코딩과 자기 일관성 전략을 적용하여 생성형 모델의 확률적 변동성을 줄이고, 채점 결과의 안정성과 재현성, 채점 정확도를 향상시켰다.

관련 연구

I. 자동 에세이 채점의 발전

자동 에세이 채점(AES)의 역사는 1966년 Ellis Page가 제안한 PEG(Project Essay Grade) 시스템으로 거슬러 올라간다[2]. PEG는 문장 길이, 쉼표 빈도, 문자 수 등 글의 표면적 특징을 이용하여 점수를 통계적으로 예측하는 선구적 연구였다. 이후 1990년대 ETS의 e-rater 시스템은 자연어 처리를 활용하여 어휘 다양성, 문법 오류, 담화 구조 등 언어적 특징을 추출하는 방향으로 발전하였다[3]. Pearson의 Intelligent Essay Assessor(IEA)는 잠재 의미 분석(Latent Semantic Analysis, LSA)을 도입하여 내용적 타당성을 평가하는 새로운 접근을 제시하였다[4].

2010년대 이후 딥러닝의 부상과 함께 AES 연구는 급격히 발전하였다. 재귀 신경망(RNN)과 LSTM을 활용한 연구들이 텍스트의 순차적 의존성을 포착하는 능력을 입증하였으며[5], 이후 BERT, RoBERTa, XLNet 등 Transformer 기반 사전학습 인코더 모델이 등장하면서 QWK 지표 기준으로 이전 방법론과 비교할 수 없는 성능 향상이 이루어졌다[6]. 이들 모델은 에세이 전체를 양방향으로 인코딩하여 풍부한 문맥 표현을 생성하고, 이를 회귀 헤드에 연결하여 연속적인 점수를 예측한다. 그러나 판별 모델의 근본적 한계는 구조 자체에 있다. 점수 예측에 특화된 아키텍처는 채점 근거나 루브릭별 피드백이라는 출력을 생성할 능력이 없으며, 이는 평가의 투명성과 교육적 유용성을 본질적으로 제한한다[7].

II. 생성형 LLM 기반 자동 에세이 채점과 손실 함수 설계

GPT, LLaMA 계열 등 대규모 언어 모델의 등장은 AES 패러다임에 새로운 가능성을 열었다. LLM은 제로샷 또는 퓨샷 프롬프팅만으로도 전문 채점자의 판단을 모사할 수 있으며[8, 9], 채점 근거와 피드백을 자연어로 함께 생성하는 설명 가능한 채점의 기반을 제공한다. 그러나 점수를 텍스트 토큰으로 생성하는 구조에서는 수치적 근접성 정보가 소실된다는 근본적 한계가 있다. 표준 교차 엔트로피 손실 하에서 모델은 점수의 서열적 성질을 학습하지 못하고 각 점수를 독립적 범주로 취급하게 되며, 이는 성능 저하로 직결된다[8, 12].

이를 보완하기 위한 손실 함수 연구로, [12]은 숫자 토큰의 소프트맥스 확률로부터 기댓값을 산출해 MSE 손실로 학습하는 Number Token Loss(NTL)를 제안하였으며, [13]은 Earth Mover Distance 최적화를 통해 토큰 확률 분포를 정답 주변으로 집중시키는 방식의 유효성을 보였다. 한편 Chain-of-Thought와 최종 정답에 동일한 토큰 수준 손실을 적용할 경우 학습 편향이 발생할 수 있다는 점이 보고된 바 있다[14]. [14]은 CoT와 Answer에 손실 함수를 분리 적용하여 이러한 한계를 완화하였다. 본 연구에서는 이와 유사한 문제의식 아래, 점수 토큰과 피드백 토큰이 서로 다른 역할을 가진다는 점에 주목하여 피드백 구간에 보조 손실 함수, Semantic Alignment Loss(SAL)를 도입하였다.

III. 자기 일관성과 기대값 디코딩 추론

LLM의 확률적 생성 특성으로 인해 동일한 입력에 대해서도 매 추론마다 상이한 점수가 산출되어 평가의 신뢰성이 저하될 수 있다는 문제는 AES 실용화의 핵심 과제 중 하나다[16]. 이를 해결하기 위한 추론 전략 연구로, [15]은 자기 일관성(Self-Consistency)을 제안하였다. 그리디 디코딩 대신 다양한 추론 경로를 복수 샘플링한 후 최다 출현 답변을 최종 출력으로 선택하는 방식으로, 단일 모델로 "자기 앙상블" 효과를 달성하며 산술 및 상식 추론 과제 전반에 걸쳐 일관된 성능 향상을 입증하였다. 복수의 추론 경로 간 합의를 통해 확률적 오류를 상쇄한다는 직관에 기반하며, 이는 채점 결과의 재현성 확보에도 직접적으로 활용 가능하다.

한편 그리디 디코딩이 최고 확률 토큰만을 선택함으로써 토큰 확률 분포에 내재된 정보를 낭비한다는 문제도 제기되었다. [17]는 기대값 디코딩(Expected Value Decoding)을 통해 이를 보완하였는데, 점수 범주 토큰의 소프트맥스 확률에 해당 수치를 가중하여 기댓값을 산출함으로써 모델이 특정 범주에 과도한 확신을 보이는 허위 확실성 문제를 완화하고 인간 평가와의 상관관계를 크게 향상시켰다. 본 연구는 이 두 흐름을 추론 단계에서 적용하고 비교한다. 기대값 기반 디코딩(ED)은 단일 추론에서 점수의 연속적 수치 변환을 통해 모델 내재된 정보를 최대한 활용하고, 자기 일관성(SC)은 다중 샘플링 및 앙상블을 통해 채점 결과의 안정성과 정확성을 동시에 제고한다.

제안 방법

그림 1은 본 연구에서 제안하는 자동 에세이 채점 시스템의 전체 구조를 나타낸다. 제안 시스템은 에세이 프롬프트, 학생 에세이, 형태소 특징, 루브릭을 입력으로 받아, Llama 3.1 기반[18] LoRA 미세조정 모델을 통해 루브릭별 점수와 피드백을 단일 경로의 자동회귀 방식으로 순차 생성한다. 학습 단계에서는 교차 엔트로피 손실을 기본으로, 점수 토큰에는 점수의 서열성과 클래스 불균형을 반영하는 가중 숫자 토큰 손실과 피드백에서는 의미 정렬을 유도하는 의미 정렬 손실을 함께 적용한다. 추론 단계에서는 기대값 디코딩 혹은 자기 일관성 기반 전략을 활용하여 최종 채점 결과를 산출한다.




그림 1: 제안하는 생성형 LLM 기반 자동 에세이 채점 시스템

I. 모델 아키텍처 및 생성 형식

본 연구는 Llama 3.1을 백본 모델로 채택하고, LoRA(Low-Rank Adaptation) 기반의 파라미터 효율적 미세조정을 수행한다. 본 연구에서 Llama 3.1을 채택한 이유는 베이스라인과의 비교 실험에서 아키텍처 차이를 최대한 통제하기 위함이다. 본 연구의 베이스라인은 AI Hub에서 제공하는 공식 한국어 자동 에세이 채점기로, Llama 3.1에 LoRA를 적용한 뒤 평균 풀링된 은닉 표현에 회귀 헤드를 결합하여 점수를 예측하는 방식으로 구성된다[19, 20]. 즉, 동일한 Llama 계열 구조와 동일한 LoRA 기반 미세조정 틀을 유지한 상태에서 손실 함수와 추론 전략의 변화만으로 실제 성능 차이가 나타나는지를 검증하는데 연구의 목적이 있다. 이러한 실험 설계는 백본 아키텍처나 파라미터 규모 차이의 영향을 배제하고, 본 연구에서 제안하는 학습 및 추론 기법의 기여를 보다 직접적으로 해석할 수 있도록 한다.

생성 형식은 에세이 E 와 K 개의 루브릭 집합 $\{R_1, \dots, R_k\}$ 를 입력으로 받아, 각 루브릭에 대한 점수 토큰 s_k 와 피드백 텍스트 f_k 를 순차적으로 자동회귀 방식으로 생성하는 단일 경로(single-path) 구조를 채택한다. 전체 출력 시퀀스는 다음과 같다.

$$[s_1] [s_2] \cdots [s_k] [\textit{feedback header}] [f_1] [f_2] \cdots [f_k] \quad (1)$$

이 구조의 핵심 특징은 점수 토큰 생성 과정에서 형성된 내부 은닉 표현(hidden representation)이 자동회귀 문맥을 통해 후속 피드백 생성에 직접 반영된다는 점이다. 다시 말해, 모델은 먼저 각 루브릭에 대한 점수 판단을 수행하고, 그 판단 과정에서 형성된 상태 표현을 바

탕으로 피드백을 생성하게 된다. 이에 따라 점수 판단에 사용된 문맥 정보가 후속 피드백 생성에도 활용될 수 있어, 점수와 피드백 간의 정합성을 높일 가능성을 제공한다. 이는 점수와 피드백을 별도의 모듈이나 별도의 학습 단계에서 생성하는 방식과 구별된다.

II. 가중 숫자 토큰 손실

표준 교차 엔트로피 손실은 점수 토큰을 일반 텍스트 토큰과 동일하게 취급하므로, 점수 간 서열성 및 거리 정보를 충분히 반영하지 못한다. 예를 들어 정답 점수가 7점일 때 6점을 예측한 경우와 2점을 예측한 경우는 평가 관점에서 오류의 심각성이 현저히 다르지만, 토큰 단위 교차 엔트로피는 이를 구조적으로 구분하지 않는다. 이러한 한계를 완화하기 위해 본 연구는 숫자 토큰 확률 분포의 기대값을 직접 최적화하는 Number Token Loss (NTL)를 기반으로, 클래스 불균형을 함께 고려한 가중 숫자 토큰 손실 (Weighted Number Token Loss, WNTL)을 제안한다.

점수 토큰이 생성되는 시점에서, 모델의 전체 어휘 로짓 벡터로부터 숫자 토큰 집합 $N = \{1, 2, \dots, 9\}$ 에 해당하는 로짓만을 추출하고 부분 소프트맥스를 적용하여 숫자 토큰 확률 분포를 구성한다.

$$p(k|x) = \frac{\exp(z_k)}{\sum_{j \in N} \exp(z_j)}, \quad k \in \{1, \dots, 9\} \quad (2)$$

여기서 z_k 는 숫자 토큰 k 에 대응하는 로짓 값이다. 이로부터 점수의 기대값을 다음과 같이 계산한다.

$$E[s_t] = \sum_{k \in N} k \cdot p(k|x) \quad (3)$$

기본적인 NTL은 이 기대값과 정답 점수 y_t 사이의 평균 제곱 오차

(Mean Squared Error, MSE)를 최소화한다.

$$L_{NTL} = \frac{1}{|S_{score}|} \sum_{t \in S_{score}} (E[s_t] - y_t)^2 \quad (4)$$

여기서 S_{score} 는 점수 토큰이 위치하는 시점들의 집합이다. 모델은 정답 점수와의 거리까지 반영한 방식으로 최적화되므로, 점수 간 서열성을 일반적인 범주형 분류보다 더 직접적으로 반영할 수 있다.

또한 실제 에세이 채점 데이터는 중간 점수대에 샘플이 집중되고 극단 점수대는 희소한 불균형 분포를 보인다. 이를 추가적으로 보완하기 위해 루브릭 위치 k 와 점수 값 v 에 따라 정의되는 클래스 가중치 $w_{k,v}$ 를 도입한다. 가중치는 클래스 빈도의 역수에 기반하여 다음과 같이 산출된다.

$$w_{k,v} = clip\left(\frac{N_{total}}{n_{classes} \cdot N_{k,v}}, 0.7, 2.5\right) \quad (5)$$

여기서 N_{total} 은 전체 학습 샘플 수, $n_{classes}$ 는 점수 클래스 수, $N_{k,v}$ 는 루브릭 k 에서 점수 v 를 갖는 샘플 수를 의미한다. $clip(.)$ 연산은 가중치를 $[0.7, 2.5]$ 범위로 제한하여 과도한 재가중으로 인한 학습 불안정을 방지한다. 최종적으로 L_{WNTL} 은 다음과 같이 정의된다.

$$L_{WNTL} = \frac{1}{|S_{score}|} \sum_{t \in S_{score}} w_t (E[s_t] - y_t)^2 \quad (6)$$

L_{WNTL} 은 희소 점수대의 오차에 더 큰 학습 신호를 부여함으로써, 모

텔이 중간 점수대에 과도하게 편향되는 현상을 완화하고 극단 점수에 대해서도 보다 정확한 예측을 수행하도록 유도한다.

III. 피드백 의미 정렬 손실

피드백 학습에 표준 교차 엔트로피 손실만을 적용할 경우 두 가지 문제가 발생한다. 첫째, 동일한 의미를 다른 어휘로 표현한 피드백에 불필요한 페널티가 부과되는 표면적 편향 문제가 있다. 둘째, 점수 토큰에 비해 압도적으로 많은 피드백 토큰이 전체 손실을 지배함으로써, 점수 예측에 필요한 학습 신호가 상대적으로 약화되는 손실 지배(loss dominance) 문제가 있다. 본 연구는 피드백 토큰 위치의 교차 엔트로피에 의미론적 정렬 손실을 보완하는 Semantic Alignment Loss(SAL)를 도입하여 두 문제를 동시에 완화한다.

SAL은 정답 토큰과 예측 토큰의 표면적 일치가 아닌, 임베딩 공간 상의 의미론적 근접성을 학습 목표로 삼는다. 구체적으로, 피드백 생성 시점 t 에서 정답 토큰 y_t 의 입력 임베딩을 모델의 임베딩 행렬 E 로부터 추출하고 L2 정규화하여 정답 의미 벡터 e_{gt} 를 구성한다. 다음으로 모델의 로짓 분포에서 확률이 높은 상위 k 개 토큰 집합 T_k 를 선택하고, 재정규화된 확률 $\hat{p}^{(j)}$ 를 가중치로 하는 임베딩 가중 평균을 계산하여 예측 의미 벡터 e_t 를 정의한다.

$$e_t = \sum_{j \in T_k} \hat{p}^{(j)} \cdot \text{normalize}(E[j]) \quad (7)$$

SAL은 두 벡터 간의 코사인 거리(cosine distance)를 최소화한다.

$$L_{SAL} = \frac{1}{|S_{fb}|} \sum_{t \in S_{fb}} (1 - \cos(e_t, e_{gt})) \quad (8)$$

여기서 S_{fb} 는 피드백 토큰이 위치하는 시점들의 집합이다. 상위 k 개 토큰만을 대상으로 연산하는 이유는 전체 어휘에 대해 임베딩 가중합을 계산할 경우 메모리 요구량이 $|V| \cdot d$ 에 비례하여 급증하기 때문으로, 실제 확률 질량이 집중된 소수의 후보 토큰만을 활용하더라도 의미론적 감독 신호를 안정적으로 제공할 수 있다.

WNTL과 SAL은 값의 스케일이 상이하므로, 고정 가중치로 결합할 경우 학습 단계에 따라 특정 손실이 전체 최적화를 지배하는 불안정이 발생할 수 있다. 이를 방지하기 위해 본 연구는 현재 학습 시점의 교차 엔트로피 손실과 보조 손실의 상대적 크기를 반영한 동적 가중치 메커니즘을 채택한다. 보조 손실 가중치 w 는 다음과 같이 계산된다.

$$w = \frac{\text{detach}(L_{CE})}{\text{detach}(L_{WNTL} + L_{SAL}) + \epsilon} \quad (9)$$

여기서 $\text{detach}(\cdot)$ 는 가중치 산출 경로에서 역전파를 차단하여 학습 안정성을 확보하는 연산이며, ϵ 은 수치 안정성을 위한 소수이다. 이를 바탕으로 전체 학습 손실은 다음과 같이 정의된다.

$$L_{total} = 0.5 \cdot (L_{CE} + w \cdot (L_{WNTL} + L_{SAL})) \quad (10)$$

계수 0.5 는 전체 손실의 스케일을 교차 엔트로피 단독 학습과 유사한 범위로 유지하기 위한 정규화 인자이다. 이 메커니즘은 학습 초기 보조 손실이 빠르게 수렴하여 기여가 과도해지거나 반대로 지나치게 미미해지는 상황을 자동으로 조정함으로써, 점수 예측과 피드백 생성

간의 균형 잡힌 최적화를 가능하게 한다. 이상의 손실 함수 설계와 동적 가중치 메커니즘을 하나의 학습 루프로 통합한 전체 절차를 알고리즘 1에 요약한다. 각 학습 단계에서 점수 토큰 위치에는 WNTL을, 피드백 토큰 위치에는 SAL을 산출한 뒤, 교차 엔트로피 손실과의 상대적 크기에 따라 보조 손실 가중치를 동적으로 조정하여 최종 손실을 구성하는 과정을 단계별로 나타낸다.

Algorithm 1 Training with WNTL and SAL

Require: Target sequence $Y = [s_1] \cdots [s_K][\text{feedback_header}][f_1] \cdots [f_K]$

Require: S_{score} : set of score-token positions in Y

Require: S_{fb} : set of feedback-token positions in Y

Require: E : token embedding matrix, T_k : top- k predicted token set, ϵ : numerical stability constant

Require: w_t : class weight for score token y_t , computed from

$$w_{(k,v)} = \text{clip}\left(\frac{N_{\text{total}}}{n_{\text{classes}}N_{(k,v)}}, 0.7, 2.5\right)$$

- 1: **for** each training step **do**
- 2: Run the model and obtain logits $\{\mathbf{z}_t\}$
- 3: Compute L_{CE} on all target tokens
- 4: Compute expected scores for $t \in S_{\text{score}}$:

$$\hat{s}_t = \sum_{k=1}^9 k \frac{\exp(z_{t,k})}{\sum_{j=1}^9 \exp(z_{t,j})}$$

- 5: Compute

$$L_{\text{WNTL}} = \frac{1}{|S_{\text{score}}|} \sum_{t \in S_{\text{score}}} w_t (\hat{s}_t - y_t)^2$$

- 6: Compute predicted semantic vectors for $t \in S_{\text{fb}}$:

$$e_t = \sum_{j \in T_k} \tilde{p}(j) \text{normalize}(E[j]), \quad e_t^{\text{gt}} = \text{normalize}(E[y_t])$$

- 7: Compute

$$L_{\text{SAL}} = \frac{1}{|S_{\text{fb}}|} \sum_{t \in S_{\text{fb}}} (1 - \cos(e_t, e_t^{\text{gt}}))$$

- 8: Set

$$\lambda = \frac{\text{detach}(L_{\text{CE}})}{\text{detach}(L_{\text{WNTL}} + L_{\text{SAL}}) + \epsilon}$$

- 9: Update LoRA parameters using

$$L_{\text{total}} = 0.5 (L_{\text{CE}} + \lambda(L_{\text{WNTL}} + L_{\text{SAL}}))$$

- 10: **end for**
-

알고리즘 1: WNTL 및 SAL을 활용한 학습 절차

IV. 추론 및 디코딩 전략

학습 완료 후 추론 단계에서는 점수 예측의 정확도와 안정성을 높이기 위하여 세 가지 디코딩 전략을 비교 분석한다. 생성형 언어 모델은 동일한 입력에 대해서도 디코딩 방식에 따라 상이한 결과를 산출할 수 있으므로, 적절한 추론 전략의 선택은 자동 에세이 채점 시스템의 신뢰성과 성능으로 직접적으로 연결된다.

Top-1 Decoding(Greedy)은 점수 토큰 위치에서 소프트맥스 확률이 가장 높은 단일 토큰을 선택하는 결정론적 방식이다($t = 0.0$). 단 한번의 추론으로 결과를 산출하므로 가장 빠른 처리 속도를 제공하나, 최고 확률 토큰만을 활용함으로써 숫자 토큰 분포에 내재된 연속적 정보가 손실된다는 한계를 가진다.

기대값 디코딩(Expected Value Decoding, ED)은 Top-1과 동일하게 단일 추론을 수행하되, 최대 확률 토큰을 직접 선택하는 대신 숫자 토큰 확률 분포의 기대값을 산출하고 이를 가장 가까운 정수로 반올림하여 최종 점수를 결정한다.

$$\hat{y}_{pred} = round\left(\sum_{k=1}^9 k \cdot p(k)\right) \quad (11)$$

이 방식은 추가적인 추론 비용 없이도 점수 분포에 내재된 연속적 정보를 활용할 수 있으며, 모델이 인접 점수들 사이에 확률을 분산시키는 경우 그 불확실성을 보다 자연스럽게 반영하여 예측의 안정성을 높인다.

자기 일관성(Self-Consistency, SC)은 온도 $t > 0.0$ 의 샘플링으로 동일 입력에 대해 m 회 독립 추론을 수행하고, 생성된 m 개의 점수를 집계하여 최종 점수를 결정한다. 집계 방법으로는 Average Vote(평균 후 반올림)와 Majority Vote(최빈값)를 모두 탐색한다. Average Vote는 점수의 순서형 특성을 보존하면서 다중 추론 결과를 통합하는 반면, Majority Vote는 구현이 단순하나 점수 분포가 넓게 분산된 경우 일부 정보가 손실될 수 있다. SC의 핵심 장점은 복수의 독립 추론 경로 간 합의를 통해 확률적 샘플링 오류를 상쇄할 수 있다는 점으로, 단일 모델로부터 다양한 추론 경로를 샘플링하여 내부 앙상블(self-ensemble) 효과를 달성한다. 이는 생성형 모델의 확률적 변동성에 따른 채점 재현성 저하 문제도 완화한다.

세 전략은 추론 비용과 정확도 간의 상충 관계를 상이한 방식으로 처리한다. Top-1은 속도를 우선하며, ED는 단일 추론 내에서 분포 정보를 활용하고, SC는 다중 샘플링을 통해 채점 안정성을 극대화한다. 본 연구는 세 전략을 제안한 손실 함수와 조합하여 실험함으로써, 추론 전략이 최종 채점 성능에 미치는 영향을 종합적으로 분석한다.

실 험

I. 데이터셋 및 실험 환경

데이터셋

본 연구에서는 AI Hub의 서술형 글쓰기 평가 데이터셋[19, 20]을 사용하였다. 초등학생부터 중학생이 작성한 한국어 서술형 에세이로 구성되어 있으며, 각 에세이에 대해 두 명의 전문 채점자가 8개 세부 루브릭별로 각각 1점에서 5점까지 독립적으로 채점하였다. 본 연구에서는 제공된 두 채점자의 점수를 합산한 뒤 1을 차감하는 방식으로 변환하여, 각 루브릭의 최종 레이블을 1점에서 9점 범위로 재구성하였다. 표 1은 루브릭별 상세 설명을 나타낸다. 전체 데이터셋은 40,006개로 구성되며, 학습 데이터 32,006개, 검증 데이터 4,000개, 테스트 데이터 4,000개로 구성되었다. 각 에세이에는 루브릭별 점수와 전문가 피드백이 함께 제공되며, 본 연구에서는 이 두 정보를 모두 학습 목표로 활용하였다.

그림 2는 루브릭별 레이블 분포를 나타낸다. 전반적으로 중간 점수 구간에 데이터가 집중되어 있으며, 1점에서 3점 및 8점에서 9점 구간은 상대적으로 적게 나타난다. 이러한 불균형은 일반적인 교차 엔트로피 기반 학습에서 희소 점수 구간에 대한 예측을 어렵게 만드는 요인으로 작용한다.

모든 실험은 NVIDIA A100 GPU 환경에서 수행되었다. 표 2에 정리된 하이퍼파라미터를 공통으로 적용하였으며, 비교 공정성을 위해 모든 비교 모델에 동일한 학습 환경을 유지하였다.

Category	Rubric	Description
Task	과제 수행의 충실성	지시문 요구사항과 조건의 충실한 반영
Cont 1-3	설명의 명료성	설명 대상에 초점을 둔 명확한 서술
	설명의 구체성	구체적 세부 내용과 타당한 근거의 충분한 제시
	설명의 적절성	지시문 요구에 부합하는 내용 구성(핵심어 4개 이상 포함)
Org 1-2	문장의 연결성	문법적으로 정확한 문장 구성과 자연스러운 문장 간 흐름
	글의 통일성	일관된 주제와 흐름의 유지
Exp 1-2	어휘의 적절성	적절하고 다양한 어휘 선택과 자연스러운 문장 표현
	어법의 적절성	문법, 맞춤법, 띄어쓰기의 전반적 정확성

표 1: 루브릭별 상세 평가 기준




그림 2: 루브릭별 레이블 분포

Hyperparameter	Value
<i>Training</i>	
Backbone model	Llama 3.1-8B-Instruct
Max sequence length	2,048
Batch size (per device)	4
Gradient accumulation steps	8
Effective batch size	32
Learning rate	3×10^{-4}
Epochs	10 (early stopping patience = 3)
Precision	BF16
Quantization	QLoRA (NF4, double quantization)
Optimizer	AdamW
Seed	42
<i>LoRA</i>	
Rank (r)	16
Alpha (α)	32
Dropout	0.05
Target modules	q-proj, v-proj
Bias	None
<i>Inference (Self-Consistency)</i>	
Temperature	0.7

표 2: 학습 및 추론 하이퍼파라미터

평가 지표와 루브릭

본 연구는 자동 에세이 채점 분야에서 표준적으로 활용되는 이차 가중 카파(Quadratic Weighted Kappa, QWK)를 주요 평가 지표로 사용한다. QWK는 두 평가자(또는 모델 예측과 정답) 간의 일치도를 측정하되, 점수 간 거리에 비례하여 불일치에 가중치를 부여하는 지표로, 순서형 채점 과제에 특히 적합하다. QWK 값은 -1에서 1 사이의 범위를 가지며, 1에 가까울수록 완전한 일치를, 0은 우연 수준의 일치를, 음수는 우연보다 낮은 일치를 의미한다.

그림 3은 루브릭별 채점자 간 일치도(Inter-Rater QWK)를 나타낸다. 설명적절성(0.990)과 어법적절성(0.946)은 채점자 간 거의 완벽한 합의를 보여 해당 루브릭의 채점 기준이 명확하고 객관적임을 시사한다. 반면 어휘적절성(0.484)과 문장연결성(0.505)은 일치도가 현저히 낮아 채점 기준의 주관성이 높거나 판단 기준이 모호함을 나타낸다. 채점자 간 일치도가 낮은 루브릭은 모델에게도 본질적으로 어려운 채점 과제를 의미하며, 이는 실험 결과 해석의 중요한 맥락을 제공한다.



그림 3: 루브릭별 채점자 간 일치도 (Inter-Rater QWK).

비교 모델

표 3은 비교 실험을 위해 구성한 6가지 모델을 정리한 것이다. Baseline은 AI Hub에서 공식 제공하는 한국어 AES 모델로, Llama 3.1-8B의 최종 은닉 표현에 회귀 헤드를 결합하여 점수를 직접 예측하는 구조이다[19, 20]. 해당 데이터셋(AI Hub)은 2025년 공개되어 이를 활용한 별도의 SOTA 모델이 보고된 바 없으므로, 데이터셋과 함께 공식 제공되는 이 베이스라인을 비교 기준으로 채택하였다. 베이스라인의 구조는 점수 예측에는 효과적일 수 있으나, LLM을 인코더로만 활용하기 때문에 채점 근거를 자연어 피드백으로 생성하는 데에는 구조적 한계가 있다. 이에 본 연구는 동일한 Llama 3.1-8B를 자동회귀 생성 모델로 활용하는 방식을 기본 구조로 채택하였다. CE 모델은 이 생성 구조에 표준 Cross-Entropy 손실만을 적용한 것으로, 회귀 헤드 기반의 Baseline과 생성 기반 접근 간의 직접적인 성능 비교를 가능하게 한다. 나머지 4개 모델(CE+NTL, CE+WNTL, CE+NTL+SAL, CE+WNTL+SAL)은 CE를 기반으로 각 보조 손실을 단독 또는 조합하여 추가한 변형들로, 이를 통해 각 손실 함수의 개별 기여도와 상호작용 효과를 체계적으로 분석한다.

Model	Reg. Head	CE	NTL	SAL	Gen.	Description
Baseline	•	–	–	–	–	Llama + Regression Head
CE	–	•	–	–	•	Only CE
NTL	–	•	•	–	•	CE + NTL
NTL+SAL	–	•	•	•	•	CE + NTL + SAL
WNTL	–	•	• _w	–	•	CE + Weighted NTL
SAL+WNTL	–	•	• _w	•	•	CE + SAL + Weighted NTL (Proposed)

표 3: 손실함수 조합별 비교 실험 모델

II. 손실 함수 조합 별 성능 평가 및 비교분석

전체 성능 비교

표 4는 Top-1 Decoding 기준으로 6개 모델 변형의 루브릭별 QWK 성능을 비교한 결과이다. Overall은 8개 루브릭의 점수를 하나의 평탄화된 벡터로 간주하여 산출한 통합 QWK, Average는 각 루브릭별 QWK의 산술 평균을 나타낸다.

CE 단독 모델은 Average QWK 0.5041로 Baseline(0.5655) 대비 11.0% 하락하여, 점수를 일반 텍스트 토큰과 동일하게 생성하는 방식만으로는 수치적 서열 구조를 학습에 반영하지 못함을 실증하였다. NTL의 도입만으로 Average QWK는 0.5800으로 CE 대비 15.1% 향상되어 Baseline 수준을 회복하였으며, NTL+SAL(0.5976)과 WNTL(0.5956)은 각각 추가적인 개선을 보였다. 최종 제안 모델인 SAL+WNTL은 Average QWK 0.6117로 모든 비교 모델 중 최고 성능을 달성하였으며, 이는 Baseline 대비 +0.0462(paired bootstrap, $p<0.001$), CE 대비 +0.1076($p<0.001$)의 유의한 향상이다. Average는 개별 루브릭의 성능을 동등하게 반영하는 지표이므로, 이 결과는 SAL+WNTL이 특정 루브릭에 편중되지 않고 전체 채점 기준에 걸쳐 균형 잡힌 예측 성능을 확보하였음을 의미한다.

다만 보조 손실의 개별 기여는 지표에 따라 차이가 있다. SAL의 추가(NTL→NTL+SAL)는 Average · Overall QWK 모두에서 유의한 향상을 가져왔으나($p<0.001$), WNTL이 NTL+SAL 위에 추가하는 기

여는 Average QWK에서는 유의한 반면($+0.0141$, $p<0.001$) Overall QWK에서는 통계적으로 검출되지 않았다(-0.0027 , $p=0.40$). 실제로 Overall QWK 기준으로 NTL+SAL(0.7178)이 SAL+WNTL(0.7151)을 근소하게 상회하나 두 모델의 Overall 차이는 유의하지 않다. 즉 WNTL의 효과는 전체 점수 예측의 절대적 향상이라기보다 루브릭 간 균형(Average QWK)과 희소 점수대의 분포 복원에 집중되며, 이는 그림 6의 MAE 감소와 그림 7의 mode collapse 완화로 뒷받침된다.

범주	평가 항목	Baseline	CE	NTL	NTL+SAL	WNTL	SAL+WNTL
Task	과제 수행의 충실성	0.6153	0.5876	0.6300	0.6398	0.6458	0.6521
Cont 1	설명의 명료성	0.5441	0.4732	0.5339	0.5675	0.5638	0.5757
Cont 2	설명의 구체성	0.4867	0.3670	0.4651	0.4931	0.4989	0.5248
Cont 3	설명의 적절성	0.9457	0.9419	0.9500	0.9540	0.9523	0.9548
Org 1	문장의 연결성	0.3051	0.1971	0.3466	0.3516	0.3582	0.3870
Org 2	글의 통일성	0.5905	0.5614	0.5936	0.6064	0.6134	0.6208
Exp 1	어휘의 적절성	0.3271	0.2683	0.3410	0.3952	0.3657	0.3986
Exp 2	어법의 적절성	0.7093	0.6361	0.7800	0.7730	0.7667	0.7798
Average		0.5655	0.5041	0.5800	0.5976	0.5956	0.6117***
95% CI		[.552, .578]	[.490, .518]	[.565, .594]	[.584, .611]	[.581, .609]	[.597, .625]
Overall		0.7049	0.6471	0.6988	0.7178	0.7010	0.7151**
95% CI		[.696, .713]	[.637, .657]	[.689, .709]	[.709, .727]	[.691, .711]	[.706, .724]

표 4: 손실 함수 구성에 따른 루브릭별 채점 성능 (QWK)

루브릭별 성능과 손실 함수 기여 분석

그림 4는 모든 비교 모델의 루브릭별 QWK를 시각화한 것이다. 설명적절성이 모든 모델에서 최고 QWK를 기록한 반면, 문장연결성이 최저 QWK를 보이는 공통 패턴이 관찰된다. 그림 3에서 나타나듯이, 설명적절성은 채점자 간 일치도가 0.990으로 매우 높아 채점 기준이 명확하고, 에세이의 주제 관련 핵심 키워드 포함 여부와 같은 객관적 요소에 크게 의존하므로 모델이 학습하기 상대적으로 용이하다. 반면 문장연결성은 채점자 간 일치도가 0.505에 불과하여 주관성이 강하며, 문장 간 논리적 흐름이라는 암묵적 규칙을 이해하고 평가해야 하므로 고차원적 언어 이해가 요구된다.

그림 5는 CE 모델을 기준으로 각 보조 손실 조합의 루브릭별 QWK 개선율(%)을 히트맵으로 나타낸 것이다.

개선율은 $\frac{(QWK_{model} - QWK_{CE})}{|QWK_{CE}|} \times 100$ 으로 정의된다. NTL 단독으로도 대부분의 루브릭에서 의미 있는 개선이 관찰되며, SAL과 WNTL의 추가가 시너지 효과를 창출한다. 특히 문장연결성에서 SAL+WNTL은 CE 대비 96.4%의 개선을 달성하여, 채점자 간 일치도가 낮은 저성능 루브릭일수록 보조 손실의 효과가 더 크게 나타나는 패턴이 확인된다. 이는 명확한 채점 기준이 존재하는 루브릭은 CE만으로도 어느 정도 학습이 가능하지만, 주관성이 강한 루브릭은 추가적인 학습 신호가 필요함을 시사한다.




그림 4: 루브릭별 QWK 성능 비교



그림 5: CE 대비 루브릭별 QWK 개선율(%)

점수 구간별 오차 분석

그림 6은 예측 점수와 정답 점수를 1~9점 각 구간별로 구분하여 평균 절대 오차(MAE)를 비교한 것이다. 모든 모델에서 공통적으로 중간 점수(4~7점)에서는 낮은 MAE를 보이나 극단 점수(1~2점, 8~9점)에서 MAE가 급격히 상승하는 U자형 패턴이 나타난다. 이는 희소 클래스의 학습 데이터 절대적 부족과 다수 클래스 방향으로의 평균 회귀 경향이 복합적으로 작용한 결과이다. NTL과 WNTL이 적용된 모델들은 희소 클래스 구간(1~2점, 9점)에서의 MAE 감소가 두드러진다. 특히 WNTL 모델은 희소 클래스 구간에서 가장 낮은 MAE를 보인다. 이는 클래스 가중치가 희소 점수대의 학습 신호를 효과적으로 강화하고 있음을 보여준다.

그림 7은 CE 모델과 SAL+WNTL 모델의 루브릭별 예측 점수 비율 분포를 실제 레이블 분포와 비교한 것이다. CE 모델은 중간 점수대(5~6점)에 예측이 극단적으로 집중되어 극단 점수를 거의 예측하지 못하는 mode collapse 현상이 뚜렷하게 나타난다. 반면 SAL+WNTL 모델은 실제 분포의 다봉형 특성을 상당 부분 재현하며, 극단 점수도 어느 정도 예측함을 확인할 수 있다. 이는 WNTL의 클래스 가중치가 mode collapse를 효과적으로 억제하고 있음을 직관적으로 보여준다.




그림 6: 점수 구간 별 오차




그림 7: 정답 분포와 모델의 예측 점수 분포 비교

혼동 행렬 분석

그림 8은 어휘적절성 루브릭에 대한 6개 모델의 혼동행렬을 비교한 결과이다. 어휘적절성은 CE 대비 개선폭이 가장 크고 채점자 간 일치도가 상대적으로 낮은 항목으로, 손실 함수 구성의 차이가 예측 분포의 질적 변화로 이어지는 과정을 가장 명확하게 관찰할 수 있다.

CE 모델은 6점 이상 및 3점 이하의 점수를 거의 생성하지 못하는 중앙 편향 패턴을 보인다. 이는 교차 엔트로피가 점수 간 서열 정보를 반영하지 못함에 따라, 빈도가 높은 중간 점수대로 예측이 수렴된 결과로 해석된다. Baseline 역시 5-6점 구간에 편중되나, 회귀 기반 출력 구조로 인해 CE 대비 예측 분포가 다소 넓게 형성된다. NTL은 기대값 기반 최적화를 통해 중간 점수대의 확률 질량을 인접 구간으로 부분적으로 분산시키나, 극단 점수 영역에 대한 분별력은 여전히 제한적이다. NTL+SAL에서는 대각선 부근의 확률 질량이 전반적으로 증가하며, 특히 5-7점 구간에서 정답 또는 인접 점수로의 예측 집중도가 뚜렷하게 개선된다. SAL+WNTL은 혼동행렬 상에서 가장 선명한 대각선 패턴을 나타낸다. 특히 7점 이상의 고점수 구간과 3점 이하의 저점수 구간에서 예측 확률이 유의미하게 분포하고 있어, WNTL의 클래스 가중치가 희소 점수대의 학습 신호를 효과적으로 증폭하였음을 확인할 수 있다. 이러한 결과는 제안된 손실 함수 조합이 단순한 수치적 성능 향상에 그치지 않고, 중앙 편향을 완화하여 점수의 서열 구조에 부합하는 방향으로 예측 분포를 재구성하였음을 시사한다.




그림 8: 어휘적절성 루브릭에 대한 모델별 혼동 행렬

III. 추론 전략 별 성능 평가 및 비교분석

전체 성능 비교

표 5는 SAL+WNTL 모델에 대해 세 가지 추론 전략의 QWK 성능을 비교한 결과이다. Greedy(Top-1) 기준 Average QWK 0.6117에서 출발하여, 단순히 추론 전략을 변경하는 것만으로 추가적인 성능 향상을 달성할 수 있음을 보여준다.

기대값 디코딩(ED)은 Top-1 대비 Average QWK +0.0066, Overall QWK +0.0088의 개선을 달성하였다. 비교 대상 중 가장 작은 이 차이조차 paired bootstrap 기준 통계적으로 유의하였으며(Average 95% CI [+0.004, +0.009], $p < 0.001$), 추가 추론 비용 없이 확률 분포의 연속적 정보만으로 유의한 향상이 가능함을 보였다. 다만 루브릭 단위로는 8개 중 7개에서 개선되고 과제수행충실성에서는 소폭 하락하여 (-0.0042), 단일 추론 분포에 의존하는 ED가 특정 루브릭에서는 불리하게 작용할 수 있음을 시사한다.

자기 일관성(SC)은 모든 집계 방식에서 Top-1 대비 유의한 향상을 보였다. Average Vote는 $m=31$ 에서 Average QWK 0.6271로 비교 대상 중 최고 성능을 기록하였으며, Top-1 대비 +0.0154($p < 0.001$, 8개 루브릭 모두에서 개선) 및 ED 대비 +0.0088($p < 0.001$)의 유의한 추가 개선을 달성하였다. Majority Vote($m=39$)는 Average QWK 0.6164로 Top-1보다 우수하나($p < 0.001$) Average Vote 및 ED보다 낮았다.

범주	평가 항목	Top-1	ED	SC-Avg	SC-Maj
Task	과제 수행의 충실성	0.6521	0.6479	0.6521	0.6489
Cont 1	설명의 명료성	0.5757	0.5844	0.5950	0.5816
Cont 2	설명의 구체성	0.5248	0.5400	0.5496	0.5359
Cont 3	설명의 적절성	0.9548	0.9596	0.9597	0.9550
Org 1	문장의 연결성	0.3870	0.3897	0.4098	0.3949
Org 2	글의 통일성	0.6208	0.6216	0.6223	0.6215
Exp 1	어휘의 적절성	0.3986	0.4123	0.4311	0.4118
Exp 2	어법의 적절성	0.7798	0.7907	0.7969	0.7819
Average		0.6117	0.6183***	0.6271***	0.6164***
95% CI		[.597,.625]	[.604,.632]	[.613,.640]	[.602,.630]
Overall		0.7151	0.7239***	0.7328***	0.7205***
95% CI		[.706,.724]	[.715,.733]	[.723,.742]	[.711,.730]

표 5: 추론 전략에 따른 루브릭별 채점 성능 (QWK)

자기 일관성(Self-Consistency, SC) 실험

그림 9는 SAL+WNTL 모델에 대해 샘플 수 m 을 1에서 50까지 변화시키며 Average QWK(상)와 Overall QWK(하)의 추이를 나타낸 것이며, 각 곡선과 기준선(Top-1, ED)에는 4,000개 에세이 표본에 대한 bootstrap 95% 신뢰구간을 음영으로 함께 표시하였다. $m = 1$ 일 때 두 SC 전략 모두 Top-1보다 낮은 QWK를 기록하는데, 이는 생성형 LLM의 확률적 변동성(온도 샘플링 $t = 0.7$ 의 노이즈)이 단일 샘플에서는 오히려 성능을 저하시키며, SC의 이점이 다중 샘플 집계에서 비롯됨을 실증한다.

두 전략 간 수렴 속도에서 뚜렷한 차이가 관찰된다. Average Vote는 $m \approx 7$ 에서 Top-1을, $m \approx 11$ 에서 ED를 상회하는 반면, Majority Vote는 각각 $m \approx 15$, $m \approx 25$ 이상을 요구한다. 이는 평균 기반 집계가 점수의 순서형 정보를 보존하여 소수의 샘플로도 노이즈를 효과적으로 상쇄하는 반면, 최빈값 기반 집계는 충분한 샘플이 확보되기 전까지 불안정함을 시사한다. 나아가 모든 m 구간에서 Average Vote가 Majority Vote를 일관되게 상회하며, 이는 순서형 척도 과제에서 평균 집계의 구조적 우월성을 재확인한다.

두 지표 모두 $m \approx 31$ 부근에서 포화되며, 이후 $m \approx 50$ 까지의 증가는 약 0.002에 불과하다. 추론 시간이 m 에 비례함을 고려할 때, $m \approx 31$ 은 성능과 추론 비용 간의 실용적 균형점으로 판단된다. 한편 그림 9의 절대 QWK 신뢰구간은 에세이 간 점수 편차로 인해 서로

겹쳐 보이거나, 이는 두 전략 차이의 비유의의를 의미하지 않는다. 동일
에세이에 대한 paired 비교에서는 에세이 간 공통 분산이 상쇄되며,
그 결과는 '통계적 유의성 분석' 절(그림 11)에서 제시한다.




그림 9: Self-Consistency 샘플 수(m)에 따른 QWK 변화

추론 전략의 루브릭별 효과 분석

그림 10은 Top-1 Decoding 대비 기대값 디코딩(ED)과 자기 일관성 평균 집계(SC Avg, $m=31$)의 루브릭별 QWK 개선폭을 보여준다. SC Avg는 어휘적절성(+0.0325), 설명구체성(+0.0248), 문장연결성(+0.0227) 등 채점자 간 일치도가 상대적으로 낮은 루브릭에서 ED보다 뚜렷하게 큰 개선을 달성하였다. 이는 예측 불확실성이 높은 루브릭일수록 다중 샘플링을 통한 집계가 더 효과적임을 시사한다. 반면 채점자 간 일치도가 가장 높은 설명적절성에서는 두 전략의 개선폭이 동일하였으며(+0.0048), 과제수행충실성에서는 ED가 소폭 하락(-0.0042)한 반면 SC Avg는 Top-1 수준을 유지하여, 단일 추론 분포에 의존하는 ED가 특정 루브릭에서는 오히려 불리하게 작용할 수 있음을 보여준다. 종합하면, ED는 추가 추론 비용 없이 대부분의 루브릭에서 안정적인 개선을 제공하는 실용적 전략이며, SC Avg는 더 높은 추론 비용을 수반하지만 루브릭 전반에 걸쳐 보다 큰 폭의 성능 향상을 달성하는 전략으로 판단된다.




그림 10: ED와 SC의 루브릭별 QWK 개선폭

통계적 유의성 분석

본 절에서는 관측된 개선이 표본 변동에 기인한 것인지를 검정한다. 모든 검정은 4,000개 테스트 샘플에 대한 paired bootstrap($B=10,000$, $seed=42$)에 기반하며, 95% 신뢰구간은 percentile 방식으로, p값은 양측 검정으로 산출한다. 8개 루브릭에 대해서는 각 루브릭별 paired bootstrap과 함께 Wilcoxon 부호순위 검정을 병행한다. 추가 학습이나 추론 없이 기존 예측값만을 재표집하므로, 표 4 · 표 5의 점추정치는 그대로 유지된다.

가장 중요한 결과는 제안 시스템과 베이스라인의 비교다. 그림 11(b)에 제시한 바와 같이, 최종 제안 시스템(SAL+WNTL + SC-Avg)은 8개 모든 루브릭에서 $\angle QWK$ 가 0보다 크고 95% 신뢰구간이 0을 배제하였으며(전부 $p<0.001$), 가장 개선폭이 작은 설명적절성(+0.014)조차 신뢰구간 [+0.011, +0.017]로 0을 명확히 배제하였다. Top-1 디코딩 기준의 SAL+WNTL 역시 동일하게 8개 루브릭 모두에서 Baseline 대비 유의하였다(전부 $p<0.001$). 이는 제안된 학습 · 추론 기법이 베이스라인과 통계적으로 구분되는 개선을 전 루브릭에 걸쳐 제공함을 보인다.

추론 전략 간 비교에서도 가장 작은 차이인 ED와 Top-1의 차이가 유의하였다(Average +0.0066, 95% CI [+0.004, +0.009], $p<0.001$). SC-Avg는 Top-1 대비(+0.0154, $p<0.001$) 및 ED 대비(+0.0088, $p<0.001$) 모두 aggregate 지표에서 유의한 추가 개선을 보였다.

반면 개별 컴포넌트의 incremental 기여는 모든 루브릭에서 균일하지 않았다. WNTL이 NTL+SAL 위에 더하는 효과는 8개 루브릭 중 3개 (설명구체성, 문장연결성, 글의 통일성)에서만 유의하였고, Overall QWK 기준으로는 유의하지 않았다($p=0.40$). SC-Avg가 ED 대비 더 하는 효과 또한 8개 중 5개 루브릭에서만 유의하였으며, 과제수행충실성·설명적절성·글의 통일성에서는 검출되지 않았다(그림 11(a)). 특히 채점자 간 일치도가 0.990으로 가장 높은 설명적절성은 베이스라인 단계에서 이미 0.946에 도달해 추가 향상의 여지가 작은 ceiling 효과를 보였으며, 채점 단위가 짧은 과제수행충실성도 추론 전략 간 차이가 통계적으로 구분되지 않았다.

종합하면, 보조 손실과 추론 전략의 가치는 채점이 본질적으로 어려운 루브릭에서 가장 뚜렷하게 발현된다. 채점자 간 일치도가 가장 낮은 문장연결성(0.505)과 어휘적절성(0.484)은 모든 내부 비교(inner ablation)에서도 일관되게 유의한 개선을 보였다. 이는 제안 방법이 점수 분포가 모호하고 불균형이 큰, 즉 추가적인 학습·집계 신호가 가장 필요한 영역에서 정확히 작동함을 시사한다.

(a) 비교쌍별 루브릭 유의성

	SC-Avg vs Baseline	SAL+WNTL vs Baseline	SAL+WNTL vs NTL+SAL	SC-Avg vs Top-1	SC-Avg vs ED
과제수행 ($\kappa=0.66$)	***	***	ns	ns	ns
설명명료 ($\kappa=0.62$)	***	***	ns	***	**
설명구체 ($\kappa=0.58$)	***	***	***	***	*
설명적절 ($\kappa=0.99$)	***	***	ns	***	ns
문장연결 ($\kappa=0.51$)	***	***	**	**	**
글통일 ($\kappa=0.63$)	***	***	*	ns	ns
어휘적절 ($\kappa=0.48$)	***	***	ns	***	**
어법적절 ($\kappa=0.95$)	***	***	ns	***	*

(b) SC-Avg vs Baseline — 루브릭별 ΔQWK




그림 11: 핵심 비교쌍별·루브릭별 ΔQWK 와 통계적 유의성

결론

본 연구는 생성형 LLM 기반 자동 에세이 채점 시스템의 핵심 과제인 순서형 점수 학습의 어려움, 클래스 불균형, 피드백 학습의 학습 편향, 그리고 추론 단계의 확률적 변동성을 체계적으로 완화하기 위한 통합 프레임워크를 제안하고 실험적으로 검증하였다.

학습 단계에서의 주요 기여는 다음과 같다. NTL은 숫자 토큰 확률 분포의 기대값을 정답 점수와 직접 비교하는 MSE 손실을 통해, CE가 포착하지 못하는 점수 간 서열 거리 정보를 모델에 내재화하는 데 성공하였다. 이는 CE Only(0.5041) 대비 Average QWK를 0.5800으로 회복시키는 데 핵심적으로 기여하였다. WNTL은 클래스 불균형에 대응하는 역빈도 가중치를 NTL에 결합하여, 극단 점수 구간에서의 예측 정확도를 집중적으로 향상시켰으며, 그림 6에서 확인된 MAE 감소와 그림 7의 분포 복원이 이를 실증한다. SAL은 피드백 생성 토큰의 의미론적 정렬을 통해 점수 예측과 피드백 생성이라는 이중 목적 학습에서 두 목적 간의 상보적 시너지를 창출하였으며, NTL(0.5800) 대비 SAL+NTL(0.5976)의 추가 향상이 이를 뒷받침한다.

추론 단계에서의 기여도 주목할 만하다. 추가 학습 비용 없이 확률 분포의 기대값만을 활용하는 기대값 디코딩(Expected Value Decoding, ED)이 Top-1 대비 일관된 개선을 보였으며, 자기 일관성 (Self-Consistency, SC)는 Average Vote, $m = 31$ 에서 Baseline 대비 최종적으로 10.9%의 성능 향상을 달성하였다. 이 개선은 paired

bootstrap(B=10,000) 검정 결과 8개 모든 루브릭에서 $\angle$ QWK가 0보다 크고 95% 신뢰구간이 0을 배제하여 통계적으로 유의하였다(전부 $p < 0.001$, 그림 11). 특히 모델이 채점자 간 일치도가 낮은 루브릭에서 SC의 효과가 집중되는 패턴은, 채점 불확실성을 통계적 양상블로 상쇄하는 SC의 원리적 강점을 실증한다.

결과적으로, 제안 모델은 Baseline의 채점 정확도를 상회하면서도 루브릭별 피드백을 동시에 생성할 수 있어, 정확한 채점과 교육적 피드백 제공이라는 두 목표를 단일 생성형 모델로 달성하였음을 실증하였다. 이는 LLM 기반 AES가 적절한 학습 설계를 통해 기존 판별 모델의 채점 정확도를 상회하면서도 생성 모델만이 제공할 수 있는 설명력을 갖출 수 있음을 보여주는 의미 있는 결과이다.

본 연구의 한계와 향후 과제는 다음과 같다. 첫째, 본 연구의 보조 손실은 aggregate 지표(Average QWK) 기준에서는 유의한 개선을 보였으나, 일부 개별 컴포넌트의 추가 기여는 채점 기준이 명확하거나 채점자 간 일치도가 매우 높은 루브릭(예: 설명적절성)과 과제수행충실성에서는 통계적으로 검출되지 않았다. 특히 WNTL이 NTL+SAL 위에 더하는 효과는 Overall QWK 기준 유의하지 않았으며($p=0.40$), 그 기여는 절대 성능 향상보다 점수 분포의 균형 회복으로 해석하는 것이 타당하다. 향후 각 컴포넌트의 효과를 보다 정밀하게 분리·검증할 필요가 있다. 둘째, 본 연구는 채점 정확도(QWK) 중심으로 평가를 수행하였으므로, 생성된 피드백의 교육적 품질에 대한 정성적·정

량적 평가가 추가로 필요하다. 향후 연구에서는 인간 평가자에 의한 피드백 품질 평가 체계를 구축하고, BERTScore 등 자동 평가 지표와의 상관 분석을 통해 피드백 생성 능력을 종합적으로 검증할 필요가 있다. 셋째, 더 큰 규모의 LLM(예: 70B 파라미터 모델)과 확장된 LoRA 적용 범위가 채점 성능에 미치는 영향에 대한 연구가 필요하다. 넷째, 본 연구가 제안한 손실 함수와 추론 전략은 특정 언어에 의존하지 않는 범용 기법이나, 점수 · 피드백이 함께 라벨링된 대규모 데이터의 제약으로 한국어 서술형 데이터에 한해 검증되었다. 향후 LEAF++ [10] 등 영어권 데이터로 동일 기법의 효과를 검증하여 방법론의 범용성을 확인할 필요가 있다. 마지막으로, SC의 m 회 반복 추론은 실시간 채점 환경에서 응답 지연을 초래할 수 있으므로, 추론 비용과 성능 간 균형을 고려한 효율적 배치 전략 연구도 중요한 후속 과제이다.

참고문헌

1. H. Misgna, B.-W. On, I. Lee, and G. S. Choi, "A survey on deep learning-based automated essay scoring and feedback generation," *Artificial Intelligence Review*, Vol. 58, No. 2, 36, 2024.
2. E. B. Page, "The imminence of... grading essays by computer," *The Phi Delta Kappan*, Vol. 47, No. 5, pp. 238-243, 1966.
3. Y. Attali and J. Burstein, "Automated essay scoring with e-rater® V.2," *The Journal of Technology, Learning, and Assessment*, Vol. 4, No. 3, 2006.
4. T. K. Landauer, D. Laham, and P. W. Foltz, "The intelligent essay assessor," *IEEE Intelligent Systems*, Vol. 15, No. 5, pp. 27-31, 2000.
5. K. Taghipour and H. T. Ng, "A neural approach to automated essay scoring," in *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing*, Austin, Texas, 2016, pp. 1882-1891.
6. Y. Wang, C. Wang, R. Li, and H. Lin, "On the use of BERT for automated essay scoring: Joint learning of multi-

- scale essay representation," in Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics, 2022.
7. V. Kumar and D. Boulanger, "Explainable automated essay scoring: Deep learning really has pedagogical value," *Frontiers in Education*, Vol. 5, pp. 572367, 2020.
 8. W. A. Mansour, S. Albatarni, S. Eltanbouly, and T. Elsayed, "Can large language models automatically score proficiency of written essays?," in Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC–COLING 2024), Torino, Italia, 2024, pp. 2777–2786.
 9. S. Lee, Y. Cai, D. Meng, Z. Wang, and Y. Wu, "Unleashing large language models' proficiency in zero-shot essay scoring," in *Findings of the Association for Computational Linguistics: EMNLP 2024*, 2024, pp. 181–198.
 10. Misgna, H., & On, B. (2025-06-12). LEAF++: Enriching Essay Feedback Dataset with Trait Scores. *Proceedings of KIIT Conference*, Jeju.
 11. H. Yoo, J. Han, S.-Y. Ahn, and A. Oh, "DREsS: Dataset for rubric-based essay scoring on EFL writing," in

- Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics, Vienna, Austria, 2025, pp. 13439–13454.
12. J. Zausinger et al., "Regress, don't guess: A regression-like loss on number tokens for language models," in Proceedings of the 42nd International Conference on Machine Learning, Vol. 267, pp. 73995–74017, 2025.
 13. S. Ren, Z. Wu, and K. Q. Zhu, "EMO: Earth mover distance optimization for auto-regressive language modeling," in Proceedings of the Twelfth International Conference on Learning Representations, Vienna, Austria, 2024.
 14. S. Yang et al., "ThinkAnswer loss: Balancing semantic similarity and exact matching for LLM reasoning enhancement," in Findings of the Association for Computational Linguistics: EMNLP 2025, Suzhou, China, 2025, pp. 3325–3347.
 15. X. Wang et al., "Self-consistency improves chain of thought reasoning in language models," in Proceedings of the 11th International Conference on Learning Representations, 2023.
 16. Y. Song, G. Wang, S. Li, and B. Y. Lin, "The good, the bad,

and the greedy: Evaluation of LLMs should not ignore non-determinism," in Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies, Albuquerque, New Mexico, 2025, pp. 4195–4206.

17. K. Zawistowski, "Unused information in token probability distribution of generative LLM: Improving LLM reading comprehension through calculation of expected values," *Annals of Computer Science and Information Systems*, Vol. 41, pp. 191–197, 2024.
18. Meta, meta-llama/Llama-3.1-8B-Instruct [Internet], <https://huggingface.co/meta-llama/Llama-3.1-8B-Instruct>
19. AI-Hub, AI-Hub [Internet], <https://aihub.or.kr/>
20. AI-Hub, Descriptive writing evaluation dataset [Internet], <https://url.kr/7jfnwn>

감사의 글

학부연구생으로 처음 연구실에 들어와 연구를 시작하던 때가 아직도 선명합니다. 그때부터 3년 넘게 연구의 길을 차근차근 알려주시고, 아낌없이 지도해주신 김도국 교수님께 가장 먼저 깊이 감사드립니다. 연구가 낯설고 막막하던 순간마다 교수님께서 늘 방향을 잡아 주셨고, 어려움에 부딪힐 때마다 다시 앞으로 나아갈 수 있도록 이끌어 주셨습니다. 교수님 덕분에 연구자로서 첫걸음을 내디딜 수 있었고, 이렇게 하나의 결실을 맺게 되어 더욱 뜻깊게 느껴집니다.

함께 연구하고 토론하며 프로젝트를 진행했던 연구실 분들에게도 감사의 마음을 전하고 싶습니다. 여러 고민을 나누고 같은 목표를 향해 달려가는 과정 속에서 많은 도움을 받았고, 혼자였다면 쉽게 지나쳤을 부분들도 함께했기에 더 넓게 배우고 깊게 생각할 수 있었습니다. 연구실에서 함께한 시간들은 힘들었던 순간들까지도 돌아보면 소중한 기억으로 남아 있습니다.

마지막으로, 언제나 묵묵히 믿고 응원해주신 부모님께 진심으로 감사드립니다. 제 선택을 존중해주시고 늘 든든한 버팀목이 되어주신 덕분에 흔들리는 순간에도 끝까지 이 길을 걸어올 수 있었습니다. 그 믿음과 응원에 늘 감사드리며, 앞으로도 더 성실한 모습으로 보답할 수 있도록 노력하겠습니다.

고강희 올림