

## Optimizing Automated Essay Scoring Performance of Generative LLMs Using Multi-objective Learning and Self-Consistency

Gang Hee Go<sup>†</sup> · Doguk Kim<sup>††</sup>

### 다중 목적 학습과 Self-Consistency를 활용한 생성형 LLM의 자동 에세이 채점 성능 최적화

고 강 희<sup>†</sup> · 김 도 국<sup>††</sup>

#### ABSTRACT

In large-scale writing assessments, Automated Essay Scoring (AES) enhances scoring efficiency. However, due to the difficulty in learning ordinality among score tokens and the high variance of outputs for identical prompts, LLM-based grading systems often struggle with scoring precision and consistency. This study proposes a unified training and inference framework where a single LLM sequentially generates rubric-specific score tokens and feedback text within a single autoregressive generation path, without the need for additional modules. During training, we incorporated Number Token Loss (NTL) to reflect the hierarchical structure of ordinal scores by minimizing the error between the expected value of the number token distribution and the ground truth. To mitigate over-reliance on surface-level matching during feedback generation, we also integrated Semantic Alignment Loss (SAL) as an auxiliary objective, which aligns the predicted distribution with the semantic space surrounding the ground truth feedback. During inference, stochastic variability was statistically mitigated by generating and averaging multiple samples through Self-Consistency. On the AI Hub 'Descriptive Writing Evaluation Dataset,' the proposed method achieved an Average Quadratic Weighted Kappa (QWK) of 0.626, outperforming regression-head-based baselines. These results suggest that NTL improves score prediction precision, Self-Consistency enhances reproducibility and robustness, and SAL provides complementary learning signals for score determination.

Keywords : Essay Scoring(AES), Large Language Model(LLM), Multi-objective Learning

※ 본 연구는 과학기술정보통신부 및 정보통신기획평가원의 생성AI선도인재양성사업(IITP-2026-RS-2024-00360227)의 지원, 교육부 및 한국연구재단의 융합연구지원사업(No. NRF-2023S1A5A2A21085373)의 지원에 의해 수행되었음.

† 비 회 원 : 인하대학교 전기컴퓨터공학과 석사과정, ghko99@inha.edu, <http://orcid.org/0009-0006-1027-105X>

†† 정 회 원 : 인하대학교 인공지능공학과 조교수, dgkim@inha.ac.kr, <http://orcid.org/0000-0002-3564-7002>

Manuscript Received : January 23, 2026

Accepted : February 20, 2026

\* Corresponding Author : Doguk Kim(dgkim@inha.ac.kr)

#### 요 약

대규모 글쓰기 평가에서 자동 에세이 채점(Automated Essay Scoring, AES)은 채점 효율을 높이지만, 생성형 LLM 기반 채점은 점수 토큰의 순서형 학습이 어렵고 동일 입력에서도 출력이 달라지는 변동성으로 채점 정확도, 신뢰도 문제가 발생할 수 있다. 본 연구는 추가 회귀 헤드 없이 단일 LLM이 루브릭별 점수 토큰과 피드백 텍스트를 하나의 autoregressive 생성 경로에서 순차 생성하는 통합 학습·추론 프레임워크를 제안하였다. 학습에서는 숫자 토큰 분포 기대값과 정답 점수의 오차를 최소화하는 숫자 토큰 손실(Number Token Loss, NTL)로 순서형 점수의 위계 구조를 반영하고, 피드백 생성의 표면형 일치 과의존을 완화하기 위해 정답 피드백 주변 의미 공간으로 예측 분포를 정렬하는 보조 목적함수 의미 정렬 손실(Semantic Alignment Loss, SAL)을 결합하였다. 추론에서는 자기 일관성(Self-Consistency)으로 다회 샘플을 생성한 뒤 평균 집계하여 확률적 변동성을 통계적으로 완화하였다. AI Hub '서술형 글쓰기 평가 데이터셋'에서 제안 방법은 평균 Quadratic Weighted Kappa (QWK) 0.626를 달성해 회귀 헤드 기반 베이스라인(0.581)을 상회했다. 이는 NTL이 점수 예측 정밀도를 개선하고, 자기 일관성이 재현성과 강건성을 높이며, SAL이 점수 판정에 상보적 학습 신호를 제공함을 시사한다.

키워드 : 자동 에세이 채점, 거대언어모델, 다중목적 학습

#### 1. 서 론

글쓰기 교육은 최근 단순 점수 산출을 넘어 루브릭 기반의 구체적 피드백을 제공하는 '평가를 위한 학습'을 지향한다. 그러나 대규모 평가 환경에서 인간 채점은 막대한 시간과 비용이 소요되어 확장성을 저해하므로, 이를 보완하기 위한 자동 에세이 채점(Automated Essay Scoring, AES) 기술의 필요성이 지속적으로 대두되고 있다. 특히 교육 평가 맥락에서 AES는 동일 기준의 반복 적용을 보장하는 일관성, 그리고 동일 답안에 대해 결과가 재현되는 신뢰성(재현성), 더 나아가 표현 양식의 차이로 인해 불필요한 불이익이 발생하지 않는 공정성을 함께 만족해야 한다.

AES는 통계적 접근[1, 2]을 거쳐 인코더-회귀헤드 기반 판




Fig. 1. Training and Inference Framework of the Proposed Single-LLM AES Model

별 모델[3]로 발전하며 문맥 정보 반영 및 채점 성능의 비약적인 향상을 이루었다. 하지만 이러한 모델은 점수 예측에 최적화된 구조로 인해, 교육적 활용에서 중요한 채점 근거(피드백)를 제공하기 어렵다는 한계가 있다[4]. 이에 최근 생성형 LLM을 활용해 점수와 피드백을 동시에 생성함으로써 설명력을 확보하려는 시도가 이어지고 있으나[5, 6], 교육 평가에서 요구되는 공정성·일관성·신뢰성을 확보하는 데 있어 다음과 같은 구조적 한계가 보고되어 왔다.

첫째, 생성형 LLM의 확률적 변동성으로 인해 동일 입력에 대해서도 채점 결과가 달라져 평가의 일관성 및 재현성이 저하될 수 있다[7]. 둘째, 점수를 수치가 아닌 텍스트 토큰으로 학습할 경우 표준 교차 엔트로피(CE)는 점수들을 독립 범주로 취급하므로 점수 간 순서형 거리 구조를 충분히 반영하기 어렵고, 그 결과 점수 오차가 확대되어 신뢰성(정확도)뿐 아니라 공정성에도 취약해질 수 있다[8]. 셋째, 피드백 학습에서 정답과의 표면형 일치에 과도하게 강제하면 루브릭 의미에 기반한 추론을 약화시켜 점수 판정의 정확도와 일반화 성능에도 부정적 영향을 줄 수 있다[9, 10].

따라서 본 연구는 생성형 LLM이 루브릭별 점수 토큰과 피드백 텍스트를 단일 생성 경로에서 순차적으로 산출하도록 설계함으로써 교육적 설명력을 확보하는 동시에, 위 한계를 완화하기 위한 다중 목적 학습 및 자기 일관성(Self-Consistency)[11] 기반의 통합 학습·추론 프레임워크를 제안한다. 학습 단계에서는 점수의 수치적 위계를 직접 학습시키는 숫자 토큰 손실(Number Token Loss, NTL)[8]을 도입해 점수 간 거리 구조를 모델에 내재화하고, 피드백 생성에는 의미 정렬 손실(Semantic Alignment Loss, SAL)을 결합하여 표면적 일치 과의존을 완화하고 루브릭 의미 기반 학습을 강화한다. 추론 단계에서는 자기 일관성 전략을 적용해 다회 샘플을 평균 집계함으로써 평가 결과의 일관성·강건성·재현성을 확보한다.

마지막으로 제안한 통합 프레임워크가 회귀 기반 채점 전용 모델 대비 경쟁력 있음을 실험을 통해 보인다.

## 2. 관련 연구

### 2.1 자동 에세이 채점(AES)

AES는 1960년대 엘리스 페이지의 PEG(Project Essay Grade)

시스템에서 시작되었다[1]. 초기 시스템은 글의 표면적 특징으로 점수를 통계적으로 에뮬레이션하는 데 집중하였다. 이후 1990년대 후반 ETS의 E-rater는 자연어 처리로 언어적 특징을 추출하기 시작했고[2], Pearson의 Intelligent Essay Assessor는 잠재 의미 분석을 도입해 내용적 타당성을 평가하고자 하였다[12]. 2010년대 들어 BERT, XLNet 등 Transformer 기반 인코더 모델은 문맥 정보를 깊이 학습하며 QWK(Quadratic Weighted Kappa) 지표에서 비약적 성능 향상을 보였다[3]. 그러나 이들 모델은 점수만 출력하는 판별 구조로 인해, 교육적 활용에 중요한 '왜 해당 점수인가'에 대한 설명력을 제공하기 어렵다는 한계를 지닌다[4].

### 2.2 LLM 기반 자동 에세이 채점 및 추론 강건성

기존 AES는 점수 예측에 최적화된 판별 모델로서 점수의 근거 설명이나 피드백 제공에 한계가 있다[4]. 반면 GPT-4, Llama 3 등 LLM은 제로샷/퓨샷 프롬프팅으로 전문가 채점 판단을 모사하며, 루브릭 준거에 따른 근거와 개선 피드백을 자연어로 생성해 교육적 활용 가능성을 확장한다[6]. 또한 논지 전개, 근거-주장 연결 등 고차원적 수사적 관계 포착에 강점을 보인다[5]. 다만 생성 과정의 확률적 변동성으로 동일 답안에서도 점수와 설명이 달라져 일관성과 신뢰도를 저해할 수 있다[7]. 따라서 본 연구는 동일 입력을 다각도로 추론하고 투표/평균으로 집계하는 자기 일관성[11] 전략에 주목한다. LLM의 고차원적인 수사적 분석 능력은 살리되, 해당 기법을 통해 생성 과정의 확률적 변동성을 제어함으로써 현장 교육에서 요구하는 채점의 신뢰도와 설명력을 동시에 충족시키고자 한다.

### 2.3 LLM 학습 목표의 확장

LLM 기반 AES가 직면한 또 다른 핵심 과제는 채점 정확도의 한계이다. 선행 연구에 따르면, LLM 채점은 인코더 기반 채점 전용 모델과 비교했을 때 주요 채점 지표에서 낮은 성능을 보였다[13, 14]. 이는 LLM이 점수를 단순히 텍스트 토큰으로 생성함에 따라 점수 간의 수치적 관계를 학습하기 어렵고, 표면적인 텍스트 일치에 과도하게 의존하기 때문이다[8, 9]. 이에 [8]은 표준 교차 엔트로피(CE)가 점수를 독립적인 범주로 취급하여 수치적 근접성을 소실하는 문제를 NTL로 보완하였으며, [9]는 의미적 유사도를 고려한 완화 손실을 통해 표면적

일치 과의존 문제를 해결하고자 했다. 또한 [10]은 정답과 설명의 손실 함수를 분리하여 정답의 정확도를 제고하였다. 본 연구는 이러한 접근을 계승하여 피드백 생성에는 의미론적 유연성을, 점수 예측에는 수치적 정밀도를 동시에 확보하는 다중 목적 학습 구조를 채택한다.

### 3. 제안 방법

#### 3.1 모델 아키텍처 및 생성 형식

Fig. 1은 제안하는 모델의 전체 파이프라인 구조를 도식화한 것이다. (A)에서는 단일 LLM이 에세이와 루브릭을 입력받아 점수 토큰과 피드백을 순차적으로 생성한다. 이때 모델은 CE 손실뿐만 아니라, 점수의 수치적 위계를 학습하는 NTL과 피드백의 의미적 정렬을 돕는 SAL을 다중 목적 함수로 결합하여 최적화된다. (B)는 자기 일관성 기법의 적용을 보여주며, 동일한 입력에 대해 다수의 개별 샘플링 경로를 생성한 후 도출된 점수들을 집계함으로써 채점의 안정성과 정확도를 확보한다. 본 연구는 Llama 3.1-8B[15]를 백본으로 채택하고, LoRA (Low-Rank Adaptation) 기반의 PEFT(Parameter-Efficient Fine-Tuning)를 통해 미세조정을 수행한다. 입력은 에세이 본문과 평가 루브릭으로 구성된다. 모델은 각 루브릭에 대해 점수 토큰과 피드백 텍스트를 순차적으로 생성한다. 전체 출력 시퀀스는 Equation (1)과 같은 형태로 구성된다.

$$Y = [s_1, s_2, \dots, s_K, f_{1,1}, \dots, f_{K,1}] \quad (1)$$

이러한 생성 구조는 모델이 점수를 도출할 때 사용한 내부적 은닉 표현이 뒤따르는 피드백 생성에 직접 전이되도록 하여, 두 출력 간의 논리적 정합성을 보장한다.

#### 3.2 숫자 토큰 손실 (Number Token Loss, NTL)

본 연구는 숫자 토큰 분포의 기대값을 산출하여 정답 점수와의 오차를 최소화하는 NTL을 도입한다. 점수 토큰이 생성되는 시점에서 모델의 로짓 벡터를  $z_i \in \mathbb{R}^{|V|}$ 라 하자. 여기서  $V$ 는 전체 어휘이다. 숫자 토큰  $\mathcal{N} = \{1, 2, \dots, 9\}$ 에 해당하는 로짓만을 추출하여 부분 로짓 벡터  $z_i^{\mathcal{N}}$ 를 구성하고, 이를 소프트맥스로 정규화하여 숫자 토큰 확률 분포  $p_i^{\mathcal{N}}$ 를 Equation (2)와 같이 얻는다.

$$p_i^{\mathcal{N}} = \text{softmax}(z_i^{\mathcal{N}}) \quad (2)$$

각 숫자 토큰  $i \in \mathcal{N}$ 에 대응하는 수치값을  $v_i$ 라 할 때, 예측 점수의 기대값  $\hat{y}_i$ 는 Equation (3)와 같이 정의된다.

$$\hat{y}_i = \sum_{i \in \mathcal{N}} (p_i^{\mathcal{N}}(i) \cdot v_i) \quad (3)$$

정답 점수를  $y_i$ 라 할 때, NTL은 다음과 같이 정의된다.

$$L_{ntl} = \frac{1}{|\mathcal{S}_s|} \sum_{i \in \mathcal{S}_s} (\hat{y}_i - y_i)^2 \quad (4)$$

Equation (4)에서  $\mathcal{S}_s$ 는 점수 토큰이 위치하는 시점들의 집합이다. 이 방식은 모델이 정답 점수 주변으로 확률 질량을 집중시키도록 유도해 점수 간 거리를 학습 신호에 직접 반영한다.

#### 3.3 의미 정렬 손실 (Semantic Alignment Loss, SAL)

SAL은 피드백 생성에서 정답과의 엄격한 표면형 일치로 인한 과도한 페널티를 완화하고, 모델이 루브릭의 의미적 준거를 학습하도록 돕는 보조 목적 함수이다. 정답과 표현이 달라도 의미가 근접한 표현에 높은 확률을 부여해, 표현의 다양성을 허용하면서도 의미가 정렬된 피드백 분포를 학습하게 한다. 피드백 생성 시점  $t$ 에서 정답 토큰  $y_t$ 의 입력 임베딩을 모델의 입력 임베딩 행렬  $E \in \mathbb{R}^{|V| \times d}$ 로부터 추출하여 정규화된 벡터를  $p_t$ 라 하자. 다음으로 모델의 로짓  $z_t$ 로부터 상위  $k$ 개 토큰 집합  $\mathcal{X}_t$ 를 선정하고, 이들의 확률 가중 합으로 예측 의미 벡터  $q_t$ 를 Equation (5)와 같이 구성한다.

$$q_t = \text{normalize} \left( \sum_{i \in \mathcal{X}_t} (\pi_i \cdot \text{normalize}(E[i])) \right) \quad (5)$$

여기서  $\pi_i$ 는 상위  $k$ 개 토큰들 사이의 정규화된 확률값이다. 최종 SAL은 Equation (6)과 같이 코사인 거리를 최소화한다.

$$L_{sal} = \frac{1}{|\mathcal{S}_f|} \sum_{t \in \mathcal{S}_f} (1 - \cos(p_t, q_t)) \quad (6)$$

SAL은 정답과 어휘적으로는 다르더라도 의미적 맥락이 유사한 다양한 표현 학습을 유도한다. 이러한 정렬 기반 규제는 모델이 단순한 텍스트 복제에서 벗어나 루브릭의 본질적 의미에 더욱 집중하게 하며, 결과적으로 다중 학습 과정에서 점수와 피드백 간의 의미 정합성을 높여 채점 성능 향상을 위한 유효한 보조 신호로 작용한다.

#### 3.4 동적 가중치 결합 및 추론 안정화

NTL과 SAL은 스케일이 다르므로, 학습 과정에서 각 손실의 상대적 크기를 관찰하여 자동으로 조절하는 동적 가중치  $w$ 를 적용한다.  $w$ 와 통합 손실은 Equation (7), (8)과 같다.

$$w = \frac{\text{detach}(L_{ce})}{\text{detach}(L_{ntl} + L_{sal}) + \epsilon} \quad (7)$$

$$L \quad (8)$$

추론 단계에서는 자기 일관성을 적용한다. 모델의  $m$ 개의 서로 다른 추론 경로( $\text{temperature} = 0.7$ )를 샘플링하고, 도출된  $m$ 개 점수의 평균을 통해 최종 점수를 산출한다. 이는 생성 기반 채점의 본질적인 불안정성을 통계적으로 완화하고 신뢰도를 전문가 수준으로 확보하기 위함이다.




Fig. 2. Average QWK vs. Sample Sizes (m)

## 4. 실험 및 결과

### 4.1 실험 설정 및 데이터셋

본 연구는 AI Hub[16] ‘서술형 글쓰기 평가 데이터셋’을 활용하였다[17]. 각 에세이는 과제 충실성(Task), 설명의 명료성(Cont 1), 설명의 구체성(Cont 2), 설명의 적절성(Cont 3), 문장의 연결성(Org 1), 문장의 통일성(Org 2), 어휘(Exp 1), 어법(Exp 2) 등 총 8개의 세부 루브릭 항목에 대해 1~5점 척도로 평가되었다. 최종 학습 데이터는 두 명의 전문가 점수를 합산하여 1~9점 범위로 사용하였으며, 루브릭별 전문가 피드백 텍스트도 정답 레이블로 활용하였다. 본 실험에 사용된 전체 데이터셋은 총 40,006개로, 학습 데이터 32,006개, 검증 데이터 4,000개, 테스트 데이터 4,000개로 분할하여 구성하였다. 또한, 연구의 재현성을 위해 실험코드를 GitHub (<https://github.com/ghko99/lora-self-consistency-aes.git>)에 공개하였다.

### 4.2 베이스라인 및 비교 모델

제안 모델의 성능 분석을 위해 다음 비교군을 설정하였으며, 글쓰기 채점 성능을 비교했다.

- **Baseline:** Llama 3.1-8B에 회귀 헤드를 추가한 채점 전용 모델, AI Hub 공식 한국어 AES 베이스라인[17].
- **CE Only:** 회귀 헤드 없이 단일 Llama 모델을 표준 교차 엔트로피(CE)만으로 점수+피드백을 동시 학습.
- **CE + NTL:** CE 기반 생성 학습에 NTL을 추가해 점수의 수치 구조를 학습.
- **Proposed (CE + NTL + SAL):** NTL+SAL을 결합한 최종 제안 모델.

Table 1. Performance Comparison by Loss Function Combinations (QWK)

| Rubric  | Baseline | CE Only | CE+NTL | CE+NTL+SAL |
|---------|----------|---------|--------|------------|
| Overall | 0.705    | 0.648   | 0.700  | 0.718      |
| Task    | 0.615    | 0.591   | 0.630  | 0.640      |
| Cont 1  | 0.544    | 0.475   | 0.535  | 0.567      |
| Cont 2  | 0.487    | 0.371   | 0.466  | 0.493      |
| Cont 3  | 0.946    | 0.942   | 0.951  | 0.954      |
| Org 1   | 0.305    | 0.194   | 0.348  | 0.351      |
| Org 2   | 0.591    | 0.563   | 0.593  | 0.606      |
| Exp 1   | 0.327    | 0.267   | 0.339  | 0.395      |
| Exp 2   | 0.709    | 0.633   | 0.780  | 0.773      |
| Average | 0.581    | 0.520   | 0.593  | 0.611      |

모든 실험은 A100 GPU 환경에서 진행되었고, LoRA 및 학습 하이퍼파라미터는 동일하게 설정하였다. 평가지표는 QWK를 사용하였다.

### 4.3 손실 함수 조합에 따른 성능 분석

Table 1은 손실 함수 조합별 QWK를 비교한다. Overall은 8개 루브릭 점수를 평탄화해 계산한 QWK이며, Average는 8개 루브릭 QWK와 Overall QWK를 포함한 총 9개 QWK의 평균이다. 결과는 다음과 같다.

CE만 사용했을 때 평균 QWK는 0.520으로 베이스라인(0.581) 대비 큰 폭으로 하락했다. 이는 모델이 점수를 수치적 위계가 있는 값이 아닌 독립적인 ‘글자’ 토큰으로 취급했기 때문이다. 이로 인해 모델은 점수 간의 내재적 거리 구조를 이해하지 못하고 훈련 데이터의 표면형 일치에 과도하게 의존하게 된다.

NTL 추가 시 평균 QWK가 0.593으로 상승해 베이스라인 수준을 회복하였다. 이는 숫자 토큰 확률 분포의 기대값 오차 최소화가 점수 간 거리 구조 학습에 효과적임을 의미한다. CE+NTL+SAL은 평균 QWK 0.611로 최고 성능을 기록했다. SAL이 피드백 목적함수임에도 점수 성능이 개선된 것은, 표면적 일치를 넘어 본질적 의미에 집중하도록 유도한 결과이며, 채점 기제와 결합해 상보적 성능 시너지를 창출한 것으로 해석된다.

### 4.4 추론 전략에 따른 성능 분석

Table 2는 CE+NTL+SAL 모델의 추론 전략별 성능을 비교한다. Greedy는  $temperature = 0.0$  하에 진행되었으며, Self-Cons는  $temperature = 0.7$  하에 진행되었다. Greedy(top-1)는 시점별 최고 확률 토큰을 선택하고, Greedy(weighted)는 숫자 토큰 확률 분포 가중 평균을 반올림하는 방식이다. 자기 일관성(Self-Cons)은 동일 입력에 대해 다회 샘플링해 집계하는 방식이다. 세 방식 모두 추론 변동성을 줄이기 위한 전략이다. Greedy에서 weighted는 top-1 대비 우수했는데, 이는 NTL이 기대값 기반 신호를 제공한 것과 추론의 집계 방식이 정합될 때 성능이 개선될 수 있음을 시사한다. 또한 자기 일관성(Self-Cons)에서 전반적으로 QWK가 향상되었고, 특히 Avg가 Vote보다 우수했다. 이는 점수 예측의 순서형 특성상 평균 집계와 결합해 상보적 성능 시너지를 창출한 것으로 해석된다.

Table 2. Performance Comparison by Inference strategy (CE+NTL+SAL Model, QWK)

| Rubric  | Greedy (top-1) | Greedy (Weighted) | Self-Cons (vote, m=48) | Self-Cons (avg, m=49) |
|---------|----------------|-------------------|------------------------|-----------------------|
| Overall | 0.718          | 0.722             | 0.724                  | 0.735                 |
| Task    | 0.640          | 0.630             | 0.633                  | 0.643                 |
| Cont 1  | 0.567          | 0.559             | 0.563                  | 0.568                 |
| Cont 2  | 0.493          | 0.525             | 0.505                  | 0.531                 |
| Cont 3  | 0.954          | 0.959             | 0.956                  | 0.962                 |
| Org 1   | 0.351          | 0.354             | 0.367                  | 0.380                 |
| Org 2   | 0.606          | 0.606             | 0.603                  | 0.613                 |
| Exp 1   | 0.395          | 0.385             | 0.409                  | 0.403                 |
| Exp 2   | 0.773          | 0.787             | 0.782                  | 0.796                 |
| Average | 0.611          | 0.614             | 0.616                  | 0.626                 |

계가 정보 손실을 줄였음을 의미한다. Fig. 2에서 샘플 수 증가 시 성능이 일정 구간 상승 후 수렴하는 양상은, 운영 환경 내 연산 비용과 정밀도 간 실용적 균형점이 존재함을 시사한다.

## 5. 결 론

본 연구는 생성형 LLM 기반 AES에서 핵심 한계로 지적되는 순서형 점수 학습의 어려움, 동일 입력 대비 출력 변동성, 피드백 학습의 표면형 일치 과의존을 동시에 완화하기 위한 통합 학습·추론 프레임워크를 제안하였다. LLM이 루브릭별 점수 토큰과 피드백을 순차 생성하도록 설계함으로써, 회귀 헤드 없이 채점 결과와 교육적 근거를 함께 산출하도록 했다. 학습 단계에서는 NTL과 SAL을 도입해 점수 예측 정밀도를 개선하였다. 추론 단계에서는 자기 일관성으로 다회 샘플을 생성해 평균 집계함으로써 변동성을 줄이고 채점 강건성을 높여 성능을 향상시켰다. 또한 점수가 순서형 성격을 갖는 점에서 vote보다 평균 집계가 더 효과적임을 확인했다. 최종적으로 제안 방법은 평균 QWK 0.626을 달성해 회귀 헤드 기반 베이스라인을 상회하며, 생성형 LLM이 정확도와 재현성을 동시에 확보할 수 있음을 보였다.

결과적으로 서론에서 언급되었던 생성형 LLM 기반 AES의 핵심 한계였던 순서형 점수 학습 어려움과 출력 변동성, 그리고 피드백 학습의 표면형 일치 과의존은 본 연구의 학습·추론 설계로 완화되었음을 실험적으로 입증했다. NTL은 숫자 토큰 분포의 기대값을 정답에 수렴시키며 점수 간 거리 구조를 직접 학습하게 하여 CE Only(0.520) 대비 0.593으로 성능을 회복시켰다(Table 1). 또한 자기 일관성으로 다회 샘플을 평균 집계함으로써 확률적 변동성을 줄이면서, Greedy 대비 평균 QWK가 0.626으로 상승하여 강건성과 재현성 확보를 실증했다(Table 2). 마지막으로 SAL은 의미 기반 정렬 신호를 제공해 표면적 복제 의존을 낮추며, CE+NTL(0.593) 대비 CE+NTL+SAL(0.611)로 추가 성능 향상을 유도했다(Table 1).

다만 본 연구는 채점 정확도(QWK)에 초점을 두어, 생성 피드백의 교육적 품질에 대한 평가는 수행하지 못했다. 향후 연구에서는 인간평가 체계 구축과 자동 지표 상관 분석을 통해 피드백 품질을 정량·정성적으로 검증할 필요가 있다.

## References

- [1] Page, E. B., "The imminence of... grading essays by computer", *The Phi Delta Kappan*, Vol.47, No.5, pp.238-243, 1966.
- [2] Y. Attali and J. Burstein, "Automated essay scoring with e-rater® V.2," *The Journal of Technology, Learning, and Assessment*, Vol.4, No.3, 2006.
- [3] Y. Wang, C. Wang, R. Li, and H. Lin, "On the use of Bert for automated essay scoring: Joint learning of multi-scale essay representation," in *Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, Seattle, United States, pp.3416-3425, 2022.
- [4] V. Kumar and D. Boulanger, "Explainable automated essay scoring: Deep learning really has pedagogical value," *Frontiers in Education*, Vol.5, pp.572367, 2020.
- [5] S. Lee, Y. Cai, D. Meng, Z. Wang, and Y. Wu, "Unleashing large language models' proficiency in zero-shot essay scoring," in *Findings of the Association for Computational Linguistics: EMNLP 2024*, pp.181-198, 2024.
- [6] T. Shibata and Y. Miyamura, "LCES: Zero-shot automated essay scoring via pairwise comparisons using large language models," in *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*, Suzhou, China, pp.29988-30001, 2025.
- [7] Y. Song, G. Wang, S. Li, and B. Y. Lin, "The good, the bad, and the greedy: Evaluation of LLMs should not ignore non-determinism," in *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies*, Albuquerque, New Mexico, pp.4195-4206, 2025.
- [8] J. Zausinger et al., "Regress, don't guess: A regression-like loss on number tokens for language models," in *Proceedings of the 42nd International Conference on Machine Learning*, Vol.267, pp.73995-74017, 2025.
- [9] S. Ren, Z. Wu, and K. Q. Zhu, "EMO: Earth mover distance optimization for auto-regressive language modeling," in *Proceedings of the Twelfth International Conference on Learning Representations*, Vienna, Austria, 2024.
- [10] S. Yang et al., "ThinkAnswer loss: Balancing semantic similarity and exact matching for LLM reasoning enhancement," in *Findings of the Association for Computational Linguistics: EMNLP 2025*, Suzhou, China, pp.3325-3347, 2025.
- [11] X. Wang et al., "Self-consistency improves chain of thought reasoning in language models," in *Proceedings of the 11th International Conference on Learning Representations*, 2023.
- [12] Landauer, Thomas & Laham, Darrell & Foltz, Peter. "The intelligent essay assessor," *Intelligent Systems, IEEE* Vol.15, pp.27-31. 2000.
- [13] W. A. Mansour, S. Albatarni, S. Eltanbouly, and T. Elsayed, "Can large language models automatically score proficiency of written essays?," in *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*, Torino, Italia, pp.2777-2786, 2024.
- [14] H. Yoo, J. Han, S.-Y. Ahn, and A. Oh, "DREs: Dataset for rubric-based essay scoring on EFL writing," in *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics*, Vienna, Austria, pp.13439-13454, 2025.
- [15] Meta, *meta-llama/Llama-3.1-8B-Instruct* [Internet], <https://huggingface.co/meta-llama/Llama-3.1-8B-Instruct>
- [16] AI-Hub, *AI-Hub* [Internet], <https://aihub.or.kr/>
- [17] AI-Hub, *Descriptive writing evaluation dataset* [Internet], <https://url.kr/7jfnwn>